

LLM GEOMETRY · SELF-STUDY TEXTBOOK

大语言模型中的流形原理与应用

面向新手自学：生活故事、逐步算例、理论形象卡与双栏定义，贯通流形、表示几何、推理轨迹与工程落地

Version v2.5.0 · Build 1 · 2026-08-13

RapidAI Research

<https://rapidai.tech/research/>

更细 · 更形象 · 可自学 · 可动手

Workshop · Theory Cards · Dual Definitions · Labs · KaTeX

目录

Table of Contents · RapidAI Research · v2.5

前置

序言 · 如何使用本书 Preface

\$0 新手地图：用生活故事读懂全书 Beginner Map

预备篇 · 入门与自学

\$0A 线性代数速成 Linear Algebra

\$0B 概率、统计与高维现象 Probability

\$0C Transformer 与语言模型基础 Transformer

\$0D 术语故事集 Glossary Stories

\$0E 自学工坊：概念精讲 + 逐步算例 Workshop

\$0F 理论形象卡 Theory Cards

Part I · 总览与流形基础

\$01 概述、版图与阅读地图 Overview

\$02 流形、坐标、切空间与度量 Manifold Basics

\$02B 流形学习方法及其在 LLM 中的含义 Methods

Part II · LLM 中的几何图像

\$03 表示空间、残差流与语义流形 Representation

\$04 线性表示、概念方向与因果内积 LRH

\$05 内在维度、谱与冗余 ID

\$06 推理流形、失败几何与监测 Reasoning

Part III · 实践、应用与进阶

\$07 端到端实验流水线 Pipeline

§08 应用：可解释、对齐、RAG、PEFT	Apps
§09 进阶主题、理论边界与展望	Advanced
§10 常见问题、误区与排错	FAQ
§11 导修练习与迷你实验	Labs

附录

附录 A · 术语、公式与构建	App. A
附录 B · 阅读路线与主题索引	App. B
附录 C · 概念双栏：形式定义 x 物理直觉	App. C

序言 • 如何使用本书

Preface · How to Use This Handbook · RapidAi Research

这是一本由 **RapidAi Research** 编写的**教材级入门资料**：从§0 新手地图的生活故事讲起，再补线性代数、概率与 Transformer，然后进入流形、表示几何、内在维度、推理轨迹，并落到可复现实验与工程决策。你不需要先读完一本微分几何；若公式可怕，请先只读 §0、§0D、§0E 自学工坊与 §0F 理论形象卡。

0.1 本书解决什么问题

当你读到「表示在流形上」「概念是一个方向」「内在维度上升」「错误推理偏离轨迹」时，你应能：

1. 写出数学对象（点 / 集合 / 方向 / 轨迹）；
2. 给出可计算指标；
3. 设计对照，区分相关与因果；
4. 翻译成层选择、rank、阈值等决策。

定位：工作级几何语言 + 入门预备 + 实验纪律。不是论文堆叠，也不是玄学隐喻集。

0.2 知识结构（四层）

层级	章节	作用
新手层	§0, §0D, §0E, §0F	故事+算例+理论形象卡，适合自学
预备篇	§0A-§0C	线代 / 概率高维 / Transformer，扫盲
基础篇	§01-§02B	问题版图 + 流形定义 + 经典方法 $\leftrightarrow$ LLM
核心篇	§03-§06	表示、LRH、ID、推理流形
实践篇	§07-§11	流水线、应用、FAQ、Lab

0.3 读者与路径

路径 P0 · 零基础 (强烈推荐)

\$0 -> \$0E 工坊(每天1-2概念) -> \$0F 理论卡 -> \$0D -> \$0A 双栏 -> \$0C 看图 -> \$01。

路径 P0b · 补课加深 (再 2-4 晚)

\$0A 全文 -> \$0B -> \$0C 检查清单过关。

路径 A · 建立图像 (再 2 晚)

\$01-\$03 -> \$10 误区。

路径 B · 实验上手 (1-2 周)

\$04-\$05 -> \$07 -> \$11 Lab1-3。

路径 C · 工程落地

\$06-\$08 -> Lab4-5 -> 附录 B。

自学节奏建议

- 每晚 60-90 分钟：一节预备或一节核心 + 2 道练习；
- 每周至少半天：一个 Lab；
- 每章末检查清单全部勾完再往下。

0.4 体例

- 蓝底 prep-box：学习目标 / 预备提示；
- 双栏 dual-def：左**形式定义**、右**物理直觉**（必成对理解）；
- 概念卡片：一句话闪卡；
- 绿底 example-box：例子与协议；
- 橙底 callout：警告与纪律；
- 公式：... 行内，

...

独立；pre 中为代码；总表见附录 C。

0.5 证据纪律

1. 区分隐喻 / 工作定义 / 定理 / 实验观察；

- 2. 相关 != 因果;
- 3. 单模型单种子 = 案例;
- 4. UMAP 默认附图;
- 5. 换底座 / 模板 / 解码必须重测。

全书主线

预备知识 → 对象 → 度量 → 指标 → 干预/决策

图 P-1 四层知识地图 (建议按箭头走, 不要从 SAE 倒着学)



每层都有示意图 + 概念卡片 + 检查清单。卡住时先回预备篇, 不硬背核心公式。

读图: 本书默认学习顺序。Lab 从实践篇向前「按需回查」可以, 但从 SAE 直接入门会缺投影与协议纪律。

0.6 学习产出

- 1. 一页层曲线解读;
- 2. 一个带协议的方向文件;
- 3. 一条含随机对照的 $\Delta(\alpha)$ 曲线;
- 4. 一份失败案例反思;
- 5. (可选) Lab 报告合集。

若线代/概率不熟, 请从 \$0A 开始, 不要直接跳 \$04。若已熟悉 Transformer, 可快速浏览 \$0C 检查清单后进入 \$01。

§ 0 新手地图：用生活故事读懂全书

Beginner Map · Learn the Whole Book via Everyday Stories · RapidAi Research

如果你害怕公式，从本章开始。我们用**同一套生活场景**串起后面所有术语：你只需要记住「房间、便签、旋钮、路面、航道」五样东西。公式是这些图像的速记，不是另一门外语。

零基础 30 分钟目标：

- 能用自己的话解释：激活、层、方向、流形、干预；
- 知道做实验时必须先写清「协议四元组」；
- 知道「探针高」不等于「能控制模型」。

0.1 一个总比喻：工厂里的便签流水线

把大语言模型想成一座**句子加工厂**：

1. 原料：你输入的文字，被切成小片（token）；
2. 每片 token 领一张 **d 维便签**（激活向量），上面有几千个数字；
3. 便签放上传送带（残差流），经过很多车间（层）；
4. 每个车间可以：偷看前面 token 的便签（注意力）、在自己便签上写新内容（MLP）；
5. 最后一张便签被翻译成「下一个词的投票」（logits）。

图 0-1 新手总图：文字 -> 便签 -> 多层车间 -> 下一个词



几何分析 = 在某个车间出口，把某张便签抽出来测量、比较、轻轻推一把。

协议四元组：哪个模型 · 第几层 · 哪个位置 · 哪个挂载点(hook)

读图：后面所有「流形、方向、ID」都发生在橙色便签空间里，不是发生在屏幕显示的汉字上。

Token

激活 h

模型内部的数字便签。我们分析的主要对象。

文字切成的小片。不等于「词」。英语 often 一个词一块；中文常多字拼一块。

层 layer

传送带上的车间编号。浅层偏字面，深层偏任务与决策。

Hook

你选择「在哪个插座拔出便签」的位置名称。

0.2 五样核心图像（请背下中文名）

图像	对应术语	一句话	后文
大房间	Ambient 空间 $\mathbb{R}^d$	便签有 d 个格子，房间很大	\$0A, \$02
薄路面 / 橘子皮	流形	合法状态往往只占房间里薄薄一层	\$02
旋钮 / 箭头	概念方向 v_c	某种语义变化的主方向	\$04
影子长短	投影 / 读出	便签在旋钮轴上的刻度	\$0A, \$04
航道与偏航	推理轨迹	多步思考是否走在正确廊道	\$06

形式定义

流形（工作级）

局部像欧氏空间 $\mathbb{R}^k$ 的集合；可有弯曲与多片。

物理直觉

高速公路路面

车必须在路面上开。直升机直线（向量相减）可能抄近路掉进山谷 = 乱码/胡说。steering 太猛 = 车被掀出路面。

形式定义

概念方向与 steering

$$s = \langle h, \hat{v} \rangle; h' = h + \alpha \hat{v}.$$

物理直觉

调味旋钮

看刻度 = 探针/读出；拧旋钮 = steering；滤掉某种味道 = 消融。拧太狠菜就毁了（ α 过大）。

0.3 最小数学：只保留四则运算级别的心智

你暂时不必会证明定理。只需会这四步：

1. **加减**：两个便签可以相加；正类平均减负类平均 -> 方向雏形；
2. **数乘**：把方向乘上强度 α ；
3. **点积**：两个向量「对齐程度」的分数；
4. **长度**：先除以长度，再比方向（余弦）。

手算级例子 (不必 GPU)

便签二维：开心句平均在 $(2, 0)$ ，伤心句平均在 $(-2, 0)$ 。差是 $(4, 0)$ ，单位方向 $(1, 0)$ 。新句子状态 $(0.5, 1)$ ，点积 $0.5 > 0$ ，偏向开心一侧。把它加上 $1 \cdot (1, 0)$ 变成 $(1.5, 1)$ ，更开心一点--这就是 steering 的玩具版。

0.4 协议四元组：新手最容易翻车的地方

同一句话，换聊天模板、换层、换「取哪个 token」，便签内容都不同。所以任何实验先写：

```
model    = 哪个权重
layer    = 第几层
position= last token / 答案跨度 / ...
hook     = resid_post / attn_out / ...
```

口诀：没写协议，就没有可比的几何。两篇论文层号不同，曲线不能直接叠。

0.5 相关 vs 因果：一句话考试

	你做了什么	最多能说	还不能说
探针 / 分类准确率高	从便签读出标签	相关、看得见	推动它就会改变行为
steering 有效 + 随机对照弱	真的改了便签	在该设置下可控制	全世界通用方向

考试题：探针 95%，有没有证明「概念方向」？**没有**。只证明线性可分。必须看 $\Delta(\alpha)$ 曲线。

0.6 全书路线 (按害怕程度)

完全新手 (推荐)

§0 (本章) -> §0A 只看例题与双栏 -> §0C 图 -> §01 -> §02 热身 -> §04 故事 -> §10 FAQ -> §11 预备练习

会一点 ML

§0 快翻 -> §0A-0C 检查清单 -> §03-§07 -> Lab1-3

只想落地

0.7 术语对照速查（中文优先）

你可能听到的词	先记住的人话	别一上来想
Embedding	词/片变成第一张便签	复杂位置编码细节
Residual stream	主传送带	各种 LN 变体名
Attention	偷看并借用别人便签	多头公式展开
MLP	在自己便签上加工	激活函数选型争论
Logits	词表投票分	采样算法全部细节
Probe	外挂小读数器	可解释性哲学
Steering vector	旋钮方向	是否意识
Intrinsic dim	有效通道数	拓扑不变量
SAE	把混合汁拆成配方	第一周就训练全库

0.8 常见害怕与回应

- 「我微积分忘了」 -> 本书用工作定义 + 实验，不靠极限证明。
- 「我没有 A100」 -> Lab 可用小模型或 CPU 玩具；先会流程。
- 「论文太新跟不上」 -> 先掌握对象-度量-指标-干预四步，论文只是换皮。
- 「公式渲染/白方块」 -> 正文已尽量 ASCII；真公式在 KaTeX 里。

读完本章的自测（口述）

1. 激活是什么？在哪个「空间」里？
2. 为什么要先定层和 token 位置？
3. 探针和 steering 差在哪？
4. 流形比喻里，直升机直线对应什么错误？
5. 你下一步会读 §0A 还是 §0C？为什么？

0.9 检查清单

- ☐ 能讲工厂便签故事
- ☐ 能默写协议四元组
- ☐ 能区分相关/因果
- ☐ 知道五样核心图像
- ☐ 已选自己的阅读路线

§ 0A 线性代数速成（面向表示几何）

Linear Algebra Crash Course for Representation Geometry · RapidAi Research

本章是**入门预备**：只保留读懂后文所需的向量、矩阵、内积、投影、特征分解与低秩近似。每节都指向 LLM 中的具体对象，避免「背公式却对不上激活」。

学完本节你能：

- 把激活写成 $h \in \mathbb{R}^d$ ，解释 $\|h\|$ 、 $\cos$ 、投影；
- 手算 2D 投影与正交分解；
- 说明 PCA / SVD 在做什么，以及和「有效维」的关系；
- 看懂 $h' = h + \alpha \hat{v}$ 与 $h - \text{proj}_v h$ 。

0A.1

完全新手怎么读本章（20 分钟速通）

1. 先只看每节的「物理直觉」双栏与绿底例子，跳过长公式；
2. 用手算例 0A.1-0A.3（二维数字）；
3. 确认自己能口述：投影=影子、steering=顺着轴推、消融=砍掉影子；
4. PCA/SVD 等到 §05 或 Lab3 再精读也不迟。

若 §0 新手地图还没读，请先回 §0。

唯一必须记住的运算：点积（对应相乘再相加）+ 除以长度。会这个就能读懂余弦、投影和后面大部分几何实验。

向量、空间与激活

定义。 实向量空间 $\mathbb{R}^d$ 中的向量是有序数组 $h = (h_1, \dots, h_d)^\top$ 。两个向量可相加、可数乘。

在 LLM 里，某一层某个 token 的残差流激活就是一个 d 维向量（如 $d = 4096$ ）。一组样本的激活排成矩阵

$$H = \begin{bmatrix} h^{(1)\top} \\ \vdots \\ h^{(n)\top} \end{bmatrix} \in \mathbb{R}^{n \times d}.$$

例 0A.1（二维直觉）

令 $h = (3, 4)^\top$ 。则欧氏范数 $\|h\|_2 = \sqrt{3^2 + 4^2} = 5$ 。单位向量 $\hat{h} = h/\|h\| = (0.6, 0.8)^\top$ 。

形式定义

向量与范数

$h \in \mathbb{R}^d$; $\|h\|_2 = \sqrt{\sum_i h_i^2}$; $\hat{h} = h/\|h\|$ ($h \neq 0$)。

物理直觉

箭头 / 便签读数

有方向有长度的一击；或 d 个仪表读数。LLM：某层某 token 的状态快照。比「朝哪」时常先单位化。

向量 h

有方向、有长度的箭头。LLM 里：某一层某个 token 的激活。

范数 $\|h\|$

箭头有多长。常用欧氏长度 $\sqrt{\sum h_i^2}$ 。


单位向量 $h\text{-hat}$

只保留方向： $h/\|h\|$ 。比方向时先单位化。

坐标轴

默认「神经元轴」；也可换成 PCA 轴（换坐标系）。

图 0A-1 向量、长度与方向



读图：左边强调「又有长又有向」；右边把长度归一，只比较朝哪指。激活相似常用方向（余弦），不单看长度。

0A.2 内积、范数、角度

标准欧氏内积

$$\langle u, v \rangle = u^\top v = \sum_{i=1}^d u_i v_i, \quad \|u\| = \sqrt{\langle u, u \rangle}, \quad \cos \theta = \frac{\langle u, v \rangle}{\|u\| \|v\|}$$

更一般地，对称正定矩阵 $G \succ 0$ 给出内积 $\langle u, v \rangle_G = u^\top G v$ （后文因果内积 / 白化度量）。

- $\cos \theta \approx 1$: 方向接近;
- $\cos \theta \approx 0$: 正交;
- 相似度**依赖**内积选择，不是宇宙唯一标准。

例 0A.2

$u = (1, 0)^\top$, $v = (1, 1)^\top$. $\langle u, v \rangle = 1$, $\|u\| = 1$, $\|v\| = \sqrt{2}$, 故 $\cos \theta = 1/\sqrt{2}$ (45°)。

0A.3 矩阵运算与线性映射

矩阵 $A \in \mathbb{R}^{m \times d}$ 表示线性映射 $h \mapsto Ah$ 。LLM 中大量模块是「线性 + 非线性」：

$$\text{Linear}(h) = Wh + b, \quad W \in \mathbb{R}^{d_{\text{out}} \times d}.$$

常用：

- 乘法： $(AB)h = A(Bh)$;
- 转置： $(AB)^\top = B^\top A^\top$;
- 秩 $\text{rank}(A)$ ：列空间维数。

0A.4 子空间、基、正交

定义。 非空集合 $U \subset \mathbb{R}^d$ 对加法与数乘封闭，则称为子空间。一组线性无关且张成 U 的向量称为基；基的个数是维数 $\dim U$ 。

正交补： $U^\perp = \{z : \langle z, u \rangle = 0 \ \forall u \in U\}$ 。后文「消融一个方向」就是去掉某 1 维子空间分量。

0A.5 投影：读出与消融的核心

向单位向量 $\hat{v}$ 投影

$$\text{proj}_{\hat{v}} h = \langle h, \hat{v} \rangle \hat{v}, \quad h_{\perp} = h - \text{proj}_{\hat{v}} h$$

一般非单位 $v \neq 0$

$$\text{proj}_v h = \frac{\langle h, v \rangle}{\langle v, v \rangle} v$$

几何: $h = \text{proj}_V h + h_\perp$ 且 $\langle \text{proj}_V h, h_\perp \rangle = 0$ (欧氏情形)。


LLM:

- 读出分数 $s = \langle h, \hat{v}_c \rangle$;
- steering: $h' = h + \alpha \hat{v}_c$;
- 消融: $h \leftarrow h - \text{proj}_{v_c} h$.

例 0A.3 (手算投影)

$h = (2, 2)^\top$, $v = (1, 0)^\top$ 。则 $\text{proj}_v h = (2, 0)^\top$, $h_\perp = (0, 2)^\top$ 。沿 v steering $\alpha = 1$: $h' = (3, 2)^\top$ 。

图 0A-2 投影 = 读出; 加上 α = steering; 减去投影 = 消融



读图：影子（投影）长短 $\sim$ 概念强度；把影子砍掉 $\sim$ 消融；顺着 v 再画长一点 $\sim$ steering。这是全书干预语言的几何原点。

形式定义

投影 / 读出 / 干预

$\text{proj}_v h = \frac{\langle h, v \rangle}{\langle v, v \rangle} v$; 读出 $s = \langle h, \hat{v} \rangle$; steering
 $h + \alpha \hat{v}$; 消融 $h - \text{proj}_v h$.

物理直觉

影子·拧旋钮·滤掉味道

影子长=概念强（只看不改）；顺着轴再挪=拧旋钮（真改状态）；砍掉影子=从混合汁里滤掉一种味道。

读出 readout

看 $s = \langle h, \hat{v} \rangle$ 有多大，不改模型状态。

Steering

真的改状态： $h + \alpha \hat{v}$ ，可能改输出行为。

消融 ablation

去掉某方向分量，看能力是否下降。

正交

两方向内积为 0：理想情况下拧 A 不影响 B。

0A.6 正交矩阵与「换坐标」

若 $Q^\top Q = I$ ，则 Q 保内积与长度： $\|Qh\| = \|h\|$ 。PCA 旋转到主成分坐标，就是一类正交换系。换系后「哪个轴对应概念」可能更清楚，但不创造新信息。

0A.7 特征值、特征向量

$$Av = \lambda v, \quad v \neq 0.$$

对称矩阵 $A = A^\top$ 可正交对角化： $A = Q \text{diag}(\lambda_i) Q^\top$ 。协方差矩阵是对称半正定的，特征值 $\lambda_i \geq 0$ 表示各主成分方差。

例 0A.4

$A = \begin{pmatrix} 2 & 0 \\ 0 & 1 \end{pmatrix}$ 已对角，特征对 $(2, e_1), (1, e_2)$ 。能量更集中在第一轴。

0A.8 SVD 与低秩近似

奇异值分解

$$X = U \Sigma V^\top, \quad \Sigma = \text{diag}(\sigma_1, \dots, \sigma_r), \quad \sigma_1 \geq \dots \geq \sigma_r > 0$$

Eckart-Young：最佳秩- k 近似（Frobenius / 谱范数）

$$X_k = \sum_{i=1}^k \sigma_i u_i v_i^\top$$

这是 PCA、有效秩、LoRA「低秩更新」的共同数学后台。

0A.9 协方差、中心化、PCA

样本中心化 $\tilde{h}_i = h_i - \bar{h}$ ，协方差

$$\hat{\Sigma} = \frac{1}{n-1} \sum_{i=1}^n \tilde{h}_i \tilde{h}_i^\top.$$

PCA: 取 $\hat{\Sigma}$ 最大特征值对应方向。有效维可用

$$r_{0.95} = \min \left\{ r : \sum_{i=1}^r \lambda_i / \sum_{j=1}^d \lambda_j \geq 0.95 \right\}$$

或参与比 $PR = (\sum \lambda_i)^2 / (\sum \lambda_i^2)$ (§05)。

0A.10 伪逆与最小二乘（探针直觉）

线性模型 $y \approx h^\top w$ 。最小二乘

$$\hat{w} = \arg \min_w \|Hw - y\|_2^2$$

在列满秩时 $\hat{w} = (H^\top H)^{-1} H^\top y$ 。逻辑回归探针是其分类版（加 sigmoid 与交叉熵）。

0A.11 条件数与数值直觉

$$\kappa(A) = \frac{\sigma_{\max}(A)}{\sigma_{\min}(A)}$$

条件数大：方向估计对噪声敏感。白化、正则 (λI) 常用来稳住探针与马氏距离。

0A.12 练习（建议笔算 + 五分钟代码）

1. 对 $h = (1, 2, 2)^\top$ 求 $\|h\|$ 与 $\hat{h}$ 。
2. 用 $v = (1, 1, 0)^\top$ 计算 $\text{proj}_v h$ 与 $h_\perp$ ，验证正交。
3. 解释：为何对激活先减均值再比余弦，有时更合理？
4. 若 $\lambda = (10, 1, 0.1)$ ，求 PR 的数量级（不必算到很细）。
5. 用两句话说明 LoRA 与「低秩矩阵」的联系。

过关标准：不查资料能解释投影公式，并指出 steering / 消融各对应哪一步。然后进入 §0B。

0A.13 检查清单

- [] 分清向量 / 子空间 / 基 / 维数
- [] 会算内积、余弦、投影

- [] 知道对称矩阵特征分解与 SVD 用途
- [] 能把 PCA 能量维说成人话

§ 0B 概率、统计与高维现象

Probability, Statistics & High-Dimensional Phenomena · RapidAi Research

几何实验充满「随机样本、噪声、估计误差」。本章用最短路径回顾期望与方差、估计与置信、距离浓度、近邻与维数灾难，以及分类指标 (Acc/AUC)。目标是：看到层曲线抖动时知道该怪样本还是怪模型。

学完本节你能：

- 解释 $\mathbb{E}$, Var 与样本均值方差；
- 说明为何高维两点距离会「都差不多」；
- 正确使用 train/val/test 与随机基线；
- 读懂 ROC/AUC，不把准确率当唯一真理。

0B.1

为什么几何手册要讲概率？

你拿到的不是完美曲面，而是有噪声的一堆点。方向靠平均，曲线会抖，好看的数字可能来自运气。本章只教：平均从哪来、如何对照安慰剂、高维邻居为何不可信。

形式定义

随机基线

打乱标签或随机方向重复同一流程，得到对照分数。

物理直觉

糖丸 / 安慰剂

真药必须比糖丸强。否则「探针 90%」可能只是过拟合或类别不平衡。

随机变量与期望

离散情形 $\mathbb{E}[X] = \sum_x x p(x)$ ；连续情形积分。线性性：

$$\mathbb{E}[aX + bY] = a\mathbb{E}[X] + b\mathbb{E}[Y]$$

始终成立（不要求独立）。方差

$$\text{Var}(X) = \mathbb{E}[(X - \mathbb{E}X)^2] = \mathbb{E}[X^2] - (\mathbb{E}X)^2.$$

LLM 对照

diff-in-means 中的 $\mathbb{E}[h \mid c+]$ 在实践中是样本均值。样本量小 $\rightarrow$ 方向噪声大 $\rightarrow$ steering 不稳。

0B.2 独立、相关、协方差

$$\text{Cov}(X, Y) = \mathbb{E}[(X - \mathbb{E}X)(Y - \mathbb{E}Y)]$$

独立 $\Rightarrow$ 不相关；不相关 $\not\Rightarrow$ 独立。高维激活各坐标常相关，所以欧氏距离可能被少数高方差轴主导--白化 ($G = \hat{\Sigma}^{-1}$) 的动机之一。

0B.3 样本估计与过拟合直觉

$$\bar{x} = \frac{1}{n} \sum_{i=1}^n x_i, \quad s^2 = \frac{1}{n-1} \sum_{i=1}^n (x_i - \bar{x})^2$$

经验规则：

- 估计 d 维协方差，粗需要 n 显著大于有效参数量，否则 $\hat{\Sigma}$ 病态；
- 探针在训练点 Acc 高、测试点崩 = 过拟合；
- 随机标签仍可拟合到一定程度（尤其 d 大） $\rightarrow$ 必须设随机基线。

铁律：任何「可线性读出」的声明，至少报 held-out 指标；任何「可控制」的声明，至少报随机方向对照。

0B.4 高斯直觉与马氏距离

多元高斯 $\mathcal{N}(\mu, \Sigma)$ 的密度等值线是椭球。马氏距离

$$d_{\Sigma}(h, \mu) = \sqrt{(h - \mu)^{\top} \Sigma^{-1} (h - \mu)}$$

先按协方差「拉成球」再量欧氏距离。这与 §02 的一般度量、§04 的 G 一脉相承。

0B.5 高维现象（非常重要）

现象 1 · 距离浓度。在许多高维分布下，两点距离相对波动变小，「远近」对比度下降。



现象 2 · 维数灾难（近邻）。 k NN 在高维可能失效：邻居不再「局部」。这直接影响 ID 估计与 Purity@ k 。

现象 3 · 测度集中。Lipschitz 函数高度集中在均值附近；单点奇异值可能误导，要看分布与分位数。

入门实验（思想）

在 $\mathbb{R}^d$ 均匀采单位向量，看两两 $|\cos|$ 的直方图： $d = 2$ 很散， $d = 256$ 更集中在 0 附近。这解释：随机方向对照的 Δ_{rand} 往往接近 0，真正概念方向需要「冒尖」。

图 0B-1 低维「远近分明」vs 高维「距离差不多」



读图：高维里「邻居」不再天然可信。所以 Purity@ k 、ID 的邻域法都要：去重、够样本、看趋势，并与谱方法交叉验证。

形式定义

期望 · 基线 · AUC

$\mathbb{E}[X]$ 用 $\bar{x}$ 估；随机标签/随机方向基线；
AUC = ROC 下面积。

物理直觉

反复称重 · 对照实验 · 排序能力

均值=多次测量的平均落点；基线=「瞎猜/乱拧」对照；AUC=不先定及格线，只问好的是否普遍分更高。

样本均值

用数据平均近似期望。方向估计的根基； n 太小会抖。

随机基线

打乱标签或随机方向重做一遍，防止「显得很强大」。

AUC

看分数排序能力，不先拍一个阈值。适合探针分数。

阈值工作点

上线门控要报 FPR/FNR，不能只报最佳 Acc。

0B.6 假设检验直觉（不讲繁琐表）

比较 $\Delta(\alpha)$ 与 $\Delta_{\text{rand}}(\alpha)$ 时，本质是：观察到的改进是否像「噪声运气」？最低配置：

- 多种子重复；
- 报均值+/-标准差或分位数；
- 预注册 α 网格，避免挑最好看的一点。

0B.7 分类指标

指标	含义	注意
Accuracy	总体正确率	类别不平衡时会骗人
Precision/Recall	查准/查全	安全场景常更关心
F1	调和平均	仍依赖阈值
ROC-AUC	排序能力	阈值无关，适合探针分数

$$\text{TPR} = \frac{\text{TP}}{\text{TP} + \text{FN}}, \quad \text{FPR} = \frac{\text{FP}}{\text{FP} + \text{TN}}$$

ROC 画 TPR-FPR；AUC 是曲线下面积。§06 的 AUC_t 即逐步分数对最终对错的排序能力。

0B.8 校准与阈值

分数 $s(h)$ 高不等于概率准。门控（RAG 引用、安全 alarm）上线前要用验证集选阈值 η ，并报告 FPR/FNR 工作点，而不是只报一个「最佳 Acc」。

0B.9 采样偏差

- 只用英文百科估的几何，迁移到代码/中文会漂；
- 只用短句，忽略长上下文；
- 只用答对题建「正确流形」，会忽略虚假推理。

0B.10 练习

1. 解释：为何 $n = 50, d = 4096$ 时估计全协方差危险？
2. 类别 95% 负样本时， $\text{Acc}=95\%$ 可能意味着什么？
3. 随机方向的平均 $|\cos|$ 随 d 增大通常如何变化？
4. 设计一个「随机标签探针」步骤，写 3 行伪代码级说明。
5. $\text{AUC}=0.5$ 的含义是什么？

过关标准：能独立指出一篇「只有训练 Acc、没有对照」的几何文章的问题。然后进入 §0C。

0B.11 检查清单

- ☐ 期望/方差/协方差会用
- ☐ 理解高维距离与近邻陷阱
- ☐ 会用 held-out 与随机基线
- ☐ 会读 AUC 与阈值工作点

§ 0C Transformer 与语言模型基础

Transformer & Language Model Basics · RapidAi Research

没有 Transformer 地图，流形分析会挂错层、取错 token。本章用「状态怎么走」的视角串起 tokenization、嵌入、注意力、MLP、残差、LN、logits 与解码，为 §03 以后的 hook 协议打底。

学完本节你能：

- 画出 decoder-only 数据流；
- 解释残差流为何是主状态空间；
- 说明为何常用「最后 token」激活；
- 分清前向几何与采样解码的不同。

0C.1

和 §0 工厂故事的对接

§0 说便签在传送带上过车间。本章给车间命名：Embed 发便签、Attn 借笔记、MLP 本地加工、Unembed 变成词表投票。你不必手推梯度，但必须能指出 hook 插在哪一段皮带上。

形式定义

最后 token 协议

取序列最后位置（或最后一个非特殊 token）的激活。

物理直觉

结账口的购物车

最后位置常汇聚可见上下文。整句分类默认先看结账口；实体属性任务再改取实体货架。

语言模型在学什么

自回归 LM 建模

$$p(x_1, \dots, x_T) = \prod_{t=1}^T p(x_t \mid x_{<t})$$

训练目标通常是交叉熵（下一 token 预测）。几何分析的对象往往是计算 $p(x_t | x_{<t})$ 时的中间表示，而不是最终采样出的文本本身。

0C.2 Tokenization

文本 -> token id 序列。BPE/WordPiece 等导致：

- 「词」边界!= token 边界；
- 空格、大小写、多语言切分差异大；
- 取「答案跨度激活」时必须对齐分词。

入门建议：先统一用「序列最后一个非特殊 token」协议，再尝试跨度均值。

0C.3 嵌入与位置

$$e_t = \text{Embed}(x_t) + \text{Pos}(t) \quad (\text{或 RoPE 等相对位置, 作用于注意力})$$

绝对位置与 RoPE 对「跨位置比较激活」影响不同：比较前写清位置协议。

0C.4 残差流：主舞台

Decoder block (示意)

$$\tilde{h} = h + \text{Attn}(\text{LN}(h))$$

$$h' = \tilde{h} + \text{MLP}(\text{LN}(\tilde{h}))$$

信息以「读写残差」方式累积。分析时常见 hook：

- block 输入 / 输出；
- attn 后、mlp 后；
- LN 前或后（数值与方向都可能变）。

记法

本书主记 $h_{\ell,t} \in \mathbb{R}^d$ ：层 ℓ 、位置 t 。未声明时，默认某一固定 hook（如 residual post-MLP）。

图 0C-1 Decoder-only: 残差流是主「状态通道」



每个 token 一条状态向量沿层向前走；Attn 混合位置，MLP 写特征；几何分析 = 在 hook 点把向量扯常用：最后 token 的 post-MLP residual（决策点信息更全）。

读图：橙色横线是主舞台。你的实验日志里必须写清：在这条线上的**哪一层、哪个位置、LN 前/后**取值。

形式定义

残差流与 hook

$x_{\ell+1} = x_{\ell} + \Delta_{\text{attn}} + \Delta_{\text{mlp}}$ (LN 位置依实现)。Hook=计算图读取点；状态记 $h_{\ell,t}$ 。

物理直觉

传送带包裹·测压孔

每个 token 一个包裹沿层传送；Attn 偷看别人、MLP 往自己包里塞纸条。Hook=你在哪一站打开包裹取样--孔位不同读数不同。

Token

文本被切成的小片 id，不是总等于「词」。

残差流

层层改写的主向量通道；本书默认状态空间。

Hook

你选择读取激活的挂载点。换 hook = 换对象。

Logits

未归一化的词表分数；softmax 后才是概率。

0C.5 注意力机制

$$Q = XW_Q, K = XW_K, V = XW_V$$

$$\text{Attn}(X) = \text{softmax}\left(\frac{QK^T}{\sqrt{d_k}} + M\right)V$$

因果掩码 M 禁止看未来。多头：多组 W_Q, W_K, W_V 再拼回 d 维。几何上，注意力是数据依赖的「从其他位置搬 value」。

0C.6 MLP

$$\text{MLP}(h) = W_2 \sigma(W_1 h + b_1) + b_2$$

扩张维 $d_{\text{ff}} \gg d$ 。许多工作认为细特征在 MLP 通道更可分；SAE 也常对残差或 MLP 激活训练。

0C.7 LayerNorm / RMSNorm

归一化改变向量的尺度与部分自由度，使「方向」相对「模长」更稳定。比较跨层余弦时，确认是否在同一 LN 约定下。

0C.8 Unembedding 与 logits

$$\text{logits}_t = W_U h_{L,t} + b, \quad p(\cdot \mid x_{\leq t}) = \text{softmax}(\text{logits}_t)$$

词表方向与残差几何通过 W_U 相连。有的解释方法在 unembed 度量下讨论最近邻词。

0C.9 为何常取最后一个 token

因果模型在位置 t 预测 x_{t+1} 时，最后位置聚合了可见上下文（经由注意力）。分类/拒答/情感等「对整段做决策」的探针，常用最后位置状态。对「某实体词」的属性，可能更应取实体跨度。

0C.10 解码：几何之外的一层随机性

模式	对几何分析的影响
贪心 / beam	轨迹较集中
温度采样	覆盖更广，失败模式更多样
top-p	截断尾部，改变盆地访问频率

前向激活（同一输入）是确定的（固定精度下）；生成轨迹是随机的。\$06 必须固定解码协议并多样本。

0C.11 指令模型 vs 基座

- Chat 模板、system 提示会显著改变几何；
- 对齐后拒答方向更可见；
- 比较两模型前先对齐模板，否则在比较「提示工程」而非模型。

0C.12 实践：一次前向你要记录什么

```
model_id, revision
tokenizer_id
prompt_template_version
hook_point          # e.g. blocks.12.hook_resid_post
token_position      # e.g. last_nonspecial
dtype, seed
layer_indices
```

最小伪代码

```
ids = tok.encode(prompt)
h = model.forward_with_cache(ids)
vec = h[layer][0, pos, :] # batch=0
score = cosine(vec, v_concept)
```

0C.13 练习

1. 用方框图画出：embed $\rightarrow N \times (\text{attn} + \text{mlp} + \text{residual}) \rightarrow \text{unembed}$ 。
2. 说明 Pre-LN 与 Post-LN 对 hook 选择的影响（各写一句）。
3. 为什么「同一句话不同 chat 模板」不能直接比激活？
4. 若任务是抽取答案跨度，最后 token 协议可能有什么问题？
5. 温度从 0 升到 1，对 \$06 的失败盆地覆盖可能怎样变化？

过关标准：能独立写出你的 hook 协议四元组（模型，层，位置，hook 点），并解释为何最后 token 常作为默认。然后进入 \$01。

0C.14 检查清单

- ☐ 懂自回归分解
- ☐ 懂残差流与 attn/mlp 角色
- ☐ 懂 logits 与解码区别
- ☐ 能写最小前向取向量流程

§ 0D 术语故事集：把黑话翻译成人话

Glossary Stories · Black-box Words in Plain Language · RapidAi Research

本章是「词典式阅读材料」：每个词先给**人话**，再给**别和谁搞混**，最后给**最小公式**（可跳过）。适合睡前翻，也适合组会前 5 分钟热身。

阅读法：不要一次背完。遇到正文生词，回来查对应小节；把「人话」用自己的例子改写一遍，才算记住。

0D.1 表示与几何

形式

表示 / Representation

模型把输入映到的内部向量/张量，供后续计算使用。

人话

内心草稿，不是屏幕上的字

你问模型问题时，它先在「心里」用数字打草稿，再变成回答。我们研究的是草稿，不是字体。

别搞混：表示 != 数据集里的 feature 工程表格；这里特指神经网络内部状态。

形式

流形 / Manifold

局部欧氏的集合；数据常近似落在低维流形附近。

人话

合法状态走的路/面

像城市道路网：理论上可以穿墙飞，但车只能在路上。模型「正经输出」也更常待在某些薄结构附近。

形式

内在维度 d_{id}

描述局部点云所需自由度数的估计。

人话

有效通道数，不是房间有多大

仓库有 4096 个货架（ambient d），但货物常只沿着十几条主通道堆。ID 估的是通道数。

形式

度量 / 内积

定义长度与角度的规则；一般 $\langle u, v \rangle_G = u^\top G v$ 。

人话

你用哪把尺子量「像不像」

用米尺和用「考虑地形的徒步地图」量两地距离，答案不同。余弦默认欧氏尺；白化/因果内积是换尺。

0D.2 模型内部零件

形式

残差流 Residual stream

各层读写的主通道；块输出以残差形式加回。

人话

主传送带

便签主要待在这条皮带上往前走。Attn/MLP 是两侧工位往皮带上放改动。

形式

Attention

$\text{softmax}(QK^\top/\sqrt{d_k})V$ ，对 value 做数据依赖加权。

人话

举手借笔记

当前 token 问：我该看谁？然后把别人的信息按权重抄过来。因果掩码 = 不能偷看未来的笔记。

形式

MLP

逐位置的前馈非线性：扩张再压回。

人话

自己座位上的加工

不直接问别人，先把便签拿到自己工位深加工再放回传送带。

形式

Logits / Softmax

词表上的未归一化分数；softmax 变成概率。

人话

投票分 vs 得票率

logits 是原始打分；softmax 后才像「概率」。解码还要决定怎么根据概率抽词。

0D.3 分析与控制动作

形式

线性探针

用逻辑回归等从 h 预测标签；测线性可分性。

人话

外挂温度计

不拆机器，贴个表看能不能读出「有没有发烧」。读得出 $\neq$ 你能治好病。

形式

Diff-in-means

$$v = \mathbb{E}[h|+] - \mathbb{E}[h|-].$$

人话

两堆人的位置差

笑脸照片的平均脸，减哭脸平均脸，得到「笑的方向」锥形。简单但常很好用。

形式 Steering $h \leftarrow h + \alpha \hat{v}$.	人话 轻轻推一把 在内部状态上沿某方向挪一点，看输出是否朝预期变。推太猛会摔出路面。
形式 消融 Ablation $h \leftarrow h - \text{proj}_v h$.	人话 滤掉某种味道 从混合信号里减去某一方向，看能力是否掉--判断这方向是否真被用到。
形式 随机对照 随机方向或打乱标签重复实验，作基线。	人话 安慰剂 真药得比糖丸强。否则你的「效果」可能是噪声或过拟合。

0D.4 训练与适配（工程向）

形式 LoRA 用低秩矩阵 $\Delta W = BA$ 近似全量更新。	人话 不换整栋楼，只加可拆的夹层 全量微调像改建整栋；LoRA 像加几层可拆装修。rank = 夹层有多厚。几何上常与「任务差分有效秩」同阶。
形式 RAG 检索外部文档，拼进提示再生成。	人话 开卷考试 允许翻书。几何问题：翻了书之后，内部状态有没有真的走向「证据」方向？还是仍走记忆老路？
形式 SAE 稀疏自编码器：$h \approx Df$, f 稀疏。	人话 拆混合汁配方 激活常是多特征叠在一起的浓缩汁。SAE 试图写成少数原料的配方表。先会品尝（探针）再学拆配方。

0D.5 推理与失败

形式 轨迹 $\tau = (h_t)$ 逐步或逐层状态序列。	人话 思考录像，不是终考分数 只看对错像只看进球；轨迹分析像看回放里何时丢球。
形式 错误盆地 错误吸引子邻域；状态一旦进入难离开。	人话 思维坑 一旦开始一套错理由，后面步步圆谎。监测是尽早喊「停、重想」。
形式 虚假推理 终点对但中间不在正确支撑上。	人话 蒙对答案 选项蒙对了，解题过程是编的。只看最终答案会高估模型。

0D.6 一页纸「黑话翻译」练习

把下面句子改成完全不出现英文缩写的人话（答案见文末提示）：

1. We extract resid_post at last token and fit a linear probe.
2. Diff-in-means steering shows dose-response over random baselines.
3. ID drops near the final layers while probe accuracy peaks mid-network.
4. The chain-of-thought trajectory enters a failure basin at step 3.

提示答案（先自己写再看）

1. 我们在最后一层位置的主传送带出口取出便签，训练一个线性小读数器。
2. 用两类平均差当方向去推状态，效果随推力增大而变，且强过随机乱推。
3. 靠近输出时有效通道变少，但最好读的层可能在网络中部。
4. 逐步思考的录像里，第 3 步掉进错误思维坑。

0D.7 检查清单

- [] 能不看英文解释 residual / probe / steering
- [] 能举一个生活例子说明流形
- [] 能说明 LoRA 与「低秩」的直观联系

- [] 能区分虚假推理与普通答错

§ 0E 自学工坊：概念精讲 + 逐步算例

Self-Study Workshop · Concepts with Worked Examples · RapidAI Research

本章专为**一个人自学**设计。每个概念固定四块：**是什么**（人话）-> **像什么**（形象）-> **怎么算**（逐步数字）-> **在 LLM 里干什么**（落地）。数字都很小，一张草稿纸就能跟完。学完可直接做 Lab0/Lab1。

自学节奏建议：每天 1-2 个概念（约 40 分钟）。先合上书用自己的话复述「是什么/像什么」，再核对「怎么算」。卡壳时只回看对应小节，不要整章重读。

符号约定（本章）：为防缺字，正文范数写成 $\|h\|$ ，单位向量写成 $\hat{h}$ 。公式区仍用 KaTeX 的 $\|h\|$ 、 $\hat{h}$ 。

0E.1 向量：一串有顺序的数

是什么

向量 $h = (h_1, \dots, h_d)$

固定长度的数字列表，可相加、可整体缩放。

像什么

购物清单 / 游戏人物属性条

「血量、攻击、防御」是 3 维向量；LLM 里一张激活便签常常是 4096 维属性条。

逐步算 · 二维向量

令 $a = (3, 1)$, $b = (1, 2)$ 。

- 相加: $a + b = (4, 3)$ (两个背包合并对应格)。
- 缩放: $2a = (6, 2)$ (整个人变壮一倍, 方向不变)。
- 长度: $\|a\| = \sqrt{3^2 + 1^2} = \sqrt{10} \approx 3.16$ 。
- 单位化: $\hat{a} = a/\|a\| \approx (0.95, 0.32)$ (只保留朝向)。

LLM: 同一句话在第 12 层最后 token 的激活, 就是一个这样的高维 h 。换层 = 换一张属性条。

0E.2 点积与余弦：有多「同向」

是什么

$$\langle u, v \rangle = \sum_i u_i v_i$$

$\cos \theta = \langle u, v \rangle / (\|u\| \|v\|)$, 取值大约在 $[-1, 1]$ 。

像什么

两支箭头夹角 / 两个兴趣标签重合度

$\cos \approx 1$: 几乎同向; 0: 横竖无关; -1 : 对着干。

逐步算

$$u = (1, 0), v = (1, 1)。$$

1. 点积: $1 \cdot 1 + 0 \cdot 1 = 1$ 。
2. $\|u\| = 1, \|v\| = \sqrt{2}$ 。
3. $\cos = 1/\sqrt{2} \approx 0.707$ (夹角 45 度)。

LLM: 两句近义改写的激活余弦高, 说明「草稿朝向」接近; 但不保证中间改写路径合法 (那是流形/测地的事)。

0E.3 投影: 影子有多长

是什么

$$\text{proj}_v h = \frac{\langle h, v \rangle}{\langle v, v \rangle} v$$

$h = \text{proj}_v h + h_{\perp}$, 且投影与垂直部分点积为 0。

像什么

阳光下木杆在地上的影子

影子在「概念轴」上: 影子长 = 这个概念强; 砍掉影子 = 消融; 顺着轴再挪 = steering。

逐步算 (务必跟一遍)

$$h = (2, 2), v = (1, 0) \text{ (横轴 = 「开心」轴)}。$$

1. $\langle h, v \rangle = 2 \cdot 1 + 2 \cdot 0 = 2$ 。
2. $\langle v, v \rangle = 1$ 。
3. $\text{proj}_v h = 2 \cdot (1, 0) = (2, 0)$ 。影子全在横轴。
4. $h_{\perp} = h - \text{proj} = (0, 2)$ 。竖着的部分与开心无关。
5. 读出分数: 若用单位轴 $\hat{v} = (1, 0)$, 则 $s = \langle h, \hat{v} \rangle = 2$ 。
6. steering $\alpha = 1$: $h' = h + \hat{v} = (3, 2)$, 开心分量从 2 变成 3。
7. 消融: $h \leftarrow (0, 2)$, 开心影子被滤掉。

自测: 合上书, 用 $h = (3, 4), v = (0, 1)$ 重算投影。答案: $\text{proj} = (0, 4), h_{\perp} = (3, 0)$ 。

0E.4 Diff-in-means: 两堆人的「平均差」

是什么

$$v = \bar{h}_+ - \bar{h}_-$$

正类激活均值减负类均值，再单位化得 $\hat{v}$ 。

像什么

笑脸村 vs 哭脸村的地图中心连线

连线方向粗略就是「表情」轴。样本少、混杂多时，连线会歪。

逐步算（玩具数据）

正类三点：(2, 1), (3, 0), (2.5, 0.5); 负类：(-2, 0), (-1, 1), (-2.5, 0.5)。

1. $\bar{h}_+ = (2.5, 0.5)$, $\bar{h}_- = (-1.833, 0.5)$ 。
2. $v \approx (4.333, 0)$, 几乎水平。
3. $\hat{v} \approx (1, 0)$ 。
4. 新点 $h = (0.5, 2)$: 分数 $s = \langle h, \hat{v} \rangle = 0.5 > 0$, 偏正类。

LLM: 正类=安全拒答句, 负类=顺从有害句; 在固定层取最后 token, 做同样相减, 得到拒答方向锥形。然后必须做 held-out 与随机对照。

0E.5 线性探针：外挂温度计

是什么

用 h 预测标签 y

最简：逻辑回归 $\sigma(w^\top h + b)$ 。看 test Acc / AUC。

像什么

不拆发动机，只看仪表能不能读出水温

读得出 = 信息在表示里**线性可见**。不等于拧仪表就能改发动机。

逐步理解（不必真训练）

1. 收集 1000 条句子的 h 与标签。
2. 70% 训练探针，30% 测试。
3. 同时训练一个「标签打乱」探针：若仍很高，说明你在过拟合或泄漏。
4. 只有 test 高且显著高于打乱基线，才说「线性可读」。

考试句：探针 95% 能否写进报告「我们发现了因果方向」？**不能**。只能写「线性可分/相关」。

0E.6 Steering: 轻轻推一把

是什么

$$h' = h + \alpha \hat{v}$$

扫 α 得到剂量曲线 $\Delta(\alpha)$ ，并与随机方向比。

像什么

调味旋钮 / 游戏里拉属性滑条

小角度有效、大角度糊锅。随机乱拧不应同样有效（安慰剂）。

逐步实验剧本（可照做）

1. 固定协议：模型、层、last token、hook。
2. 估 $\hat{v}$ （diff-in-means）。
3. 取 $\alpha \in \{-2, -1, 0, 0.5, 1, 2\}$ 。
4. 每个 α 生成/打分，画 $\Delta(\alpha)$ 。
5. 换 5 个随机单位向量重复，画阴影基线。
6. 记录流畅度崩坏边界（从哪起开始乱码）。

合格结论模板：「在层 L、模板 T 上， $\alpha \in [0.5, 1.5]$ 时目标指标相对随机对照提升 δ ，且困惑度增幅 $< \dots$ 」

0E.7 流形：合法状态的「路面」

是什么

局部像 $\mathbb{R}^k$ 的集合

可弯曲、可多片；数据常 = 流形 + 噪声。

像什么

高速公路 / 橘子皮 / 地毯

ambient 是整栋楼的空气；流形是你走的地毯。直升机直线（向量相减）可能穿墙。

形象推演（无公式版）

1. 瑞士卷点心：面皮是 2 维，却卷在 3 维空间。
2. 两点在空间里很近，沿面皮走可能要绕一大圈。
3. LLM：两个激活余弦高，但线性插值中间句可能语法崩溃 = 弦长抄近路穿洞。
4. steering 太大 = 车被掀出路面，输出乱码。

工作定义提醒：本书说「语义流形/推理流形」是可实验的工作对象，不是已证明的数学定理。

0E.8 切空间：脚边一小块平板

是什么

$$T_p M$$

点 p 处一阶线性近似，维数 = 流形维 k 。

像什么

爬山时脚下的木板

只在一小步内，地面可以当平面。走太远，木板模型失效。LRH 额外赌：有些概念的「坡度方向」大范围内差不多。

和 steering 的关系

小 α 的 $h + \alpha \hat{v}$ 像沿着切方向迈一小步；大 α 是一阶近似使用说明书之外的操作，失败不奇怪。

0E.9 内在维度：有效通道数

是什么

$$d_{\text{id}} / \text{PR} / r_{0.95}$$

点云实际需要多少自由度的估计；必须与 ambient d 一起报。

像什么

4096 个货架，货只堆在十几条主通道

PR 小 = 能量集中在少数通道；不等于模型变笨，可能是压缩得好。

逐步算·参与比 PR

假设三根轴方差 $\lambda = (10, 1, 0.1)$ （其余为 0 可忽略）。

1. $\sum \lambda = 11.1$, $(\sum \lambda)^2 = 123.21$ 。
2. $\sum \lambda^2 = 100 + 1 + 0.01 = 101.01$ 。
3. $\text{PR} \approx 123.21 / 101.01 \approx 1.22$ 。
4. 解读：几乎像 1 条主通道，不是 3 维均分。

能量维：10/11.1 $\approx 90\%$ ，要到 95% 需要前两根： $r_{0.95} = 2$ 。

LLM：对每层激活估 PR，画层曲线；中部高、近输出降，是常见故事线，但是否如此以你的数据为准。

0E.10 残差流与层：传送带车间

是什么

$$x_{\ell+1} = x_{\ell} + \text{Attn} + \text{MLP}$$

主状态通道被各块「加写」。

像什么

皮带上的产品，两侧工位贴标签、改配件

hook = 你选择在哪个工位出口抽检。

形象对照表

零件	人话	抽检时常问
Embed	发第一张便签	词表几何
Attn	借别人笔记	在看谁？
MLP	本地深加工	细特征是否可分
Unembed	变成词表投票	谁被写进 logits

0E.11 协议四元组：自学最容易翻车处

错误示范 vs 正确示范

错误：「我在 Llama 上做了情感方向。」（哪一层？聊天模板？取哪个 token？）

正确：

```
model: Llama-3-8B-Instruct (rev xxx)
layer: 16
position: last non-special token
hook: blocks.16.hook_resid_post
template: chat_template_v3
dtype: bf16
n: 2000 pos / 2000 neg
```

换其中任一项，曲线都可能变。自学日记里请把这格当「实验身份证」。

0E.12 相关 vs 因果：一张决策表

你看到	最多能写	下一步
UMAP 两团颜色分开	可视化暗示	Purity / 探针
探针 test Acc 高	线性可读（相关）	steering / 消融
$\Delta(\alpha)$ 高于随机	该设置下可干预	OOD、串扰、剂量边界
换模板后失效	方向绑定协议	重估或条件化方向

0E.13 推理轨迹：思考录像

是什么

$$\tau = (h_0, \dots, h_T)$$

逐步状态；正确轨迹支撑叫推理流形（工作定义）。

像什么

夜航航道 + 雷达测偏

终点进港却中途搁浅 = 虚假推理（蒙对）。

迷你故事题

学生做题：第 1 步行；第 2 步抄错条件；第 3-5 步认真算；最后凑巧答案对。

- 最终答案正确 -> 像 pass@1 亮绿灯。
- 轨迹分析 -> 在第 2 步已入错误盆地。
- 监测 -> 若 $d(h_t, c)$ 在第 2 步爆表，应早停重想，而不是为蒙对鼓掌。

0E.14 LoRA rank：夹层有多厚

是什么

$$\Delta W = BA, \text{ 秩 } r$$

低秩更新； r 可用任务前后激活差分的有效秩启发。

像什么

不拆楼，只加可拆夹层装修

r 太小：装不下任务变化；太大：贵且易过拟合。先估 $\hat{r}$ 再在 $\{\hat{r}/2, \hat{r}, 2\hat{r}\}$ 网格搜。

0E.15 叠加：浓缩混合汁

形象

冰箱里只有 3 个格子 ($d = 3$)，却要放 30 种调料（特征）。只好把多种调料混进同一格。结果：拧「甜」可能带出「辣」（串扰）。SAE 试图写配方表把混合汁拆开；但拆开后仍要做干预验证，不能只看重建误差。

0E.16 一整条最小故事链（串联全书）

1. 有一张便签 h (§0A/0C)。
2. 合法便签常躺在薄路面上 (§02 流形)。
3. 路面局部可当平板，概念变化像某个坡度（切空间 / LRH）。
4. 用两堆样本均差值估坡度方向（diff-in-means）。

- 5. 温度计读得出（探针）只是相关。
- 6. 推一把真改变行为（steering+对照）才是因果。
- 7. 通道是否太多太少用 PR/ID 看 (§05) 。
- 8. 多步思考看航道偏不偏 (§06) 。
- 9. 写入一页纸决策：层、阈值、rank、失效样例 (§07-08) 。

自学检查（请写在纸上）

- 1. 不看公式，解释投影、steering、消融。
- 2. 手算： $h = (4, 2)$, $v = (1, 1)$, 求 $\text{proj}_v h$ (提示：先算点积=6, $\|v\|^2 = 2$, 投影= $(3, 3)$) 。
- 3. 为什么协议四元组缺一项就无法复现？
- 4. PR=1.2 而 $d = 4096$ 说明什么？不说明什么？
- 5. 用航道故事说明虚假推理。

0E.17 与后文地图

本章小节	精读正文	可做
0E.1-0E.3	§0A	纸笔练习
0E.4-0E.6	§04, §07	Lab2
0E.7-0E.8	§02	口述+插值思想实验
0E.9	§05	Lab3
0E.10-0E.11	§0C, §03	Lab1
0E.13	§06	Lab4
0E.14-0E.15	§08, §09	Lab5 / 选修

0E.18 检查清单

- [] 每个概念能讲人话 + 举一个生活例子
- [] 投影手算全对
- [] 能默写协议四元组
- [] 能背相关/因果决策表

- [] 能用一条故事链串起全书

§ 0F 理论形象卡：把定理级说法变成可摸的东西

Theory Image Cards · Make Abstract Claims Touchable · RapidAI Research

学术文章里的「假设 / 命题 / 经验律」往往一句带过。本章把本书用到的**核心理论说法**做成形象卡：**主张什么、不主张什么、生活类比、最小验证、失败长什么样**。适合自学时当「理论说明书」。

0F.1 流形假设 (Manifold Hypothesis)

主张：高维观测数据常常集中在较低维的结构附近（可弯曲、可分片）。

不主张：数据一定光滑、连通、无噪声；也不等于「世界是 2D」。

类比：夜空照片有数百万像素，但星体只占稀疏结构；或城市活动主要发生在道路网上。

最小验证：有效维 $d_{\text{id}} \ll d$ ；局部邻域呈低维；插值/改写是否保持合法性。

失败样子：噪声充满整个房间；任意方向都差不多；ID 接近 ambient。

0F.2 线性表示假设 LRH

主张（弱）：某些概念在表示空间中可沿低维子空间读出。

主张（强）：可用单一方向，并在加性干预下因果改变行为。

不主张：所有人类概念都是一根完美箭头；也不保证跨模型永久有效。

类比：调音台上的推子--有的音轨真有独立推子，有的音轨和别的绑死。

最小验证：探针（相关）+ $\Delta(\alpha)$ 对随机对照（因果）+ 跨提示抽样。

失败样子：探针高但 steering 无效；或一推就全面崩坏；或只对训练句式有效。

0F.3 叠加 (Superposition)

主张：特征数可远大于维数 d ，多个特征挤用同一方向资源。

不主张：完全无法解释；也不等于「没有线性结构」。

类比：宿舍只有 4 个插座，10 台设备用插排--省空间，但互相跳闸（串扰）。

最小验证：多概念联合干预的串扰矩阵；SAE 原子是否可单独因果。

失败样子：你以为拧的是「礼貌」，实际「安全感」和「啰嗦」一起飙。

0F.4 因果内积 / 换尺子

主张：欧氏点积未必匹配「概念可加」；存在更合适的 G 使方向更正交、干预更稳。

不主张：存在唯一神圣内积；白化万能。

类比：地图用不同投影，角度与面积的保真点不同；量「像不像」要选对尺子。

最小验证：换 $G = I$ vs $G = \hat{\Sigma}^{-1}$ 后，类比算术与多方向 steering 串扰是否改善。

失败样子：样本不够却强行估 Σ^{-1} ，噪声被放大，方向更抖。

0F.5 有效维与压缩

主张：谱能量与邻域几何可揭示「实际自由度」；对层选择、LoRA rank、剪枝有启发。

不主张： d_{id} 是智商；更不主张 ID 越低越好。

类比：电视台有 100 个频道，晚间真正在播的只有十几个。

最小验证：PR 与 $r_{0.95}$ 同向；分层/分任务报告；与探针曲线对照。

失败样子：把 UMAP 的 2 维当成 ID=2；或混合多领域点云硬报一个数。

0F.6 推理流形（工作假说）

主张：正确多步推理的状态轨迹，相对错误轨迹，更集中在可监测的低维廊道。

不主张：只有唯一正确路径；也不主张现有原型距离已完备。

类比：标准航线走廊 vs 迷航；可有多条合法航线（多原型）。

最小验证：逐步 AUC、早可分步 t^* 、taxonomy 稳定、干预可拉回。

失败样子：只看最终对错；伪原型把虚假推理当正确航道。

0F.7 「局部线性」为什么到处出现

一条主线串起来

曲线在放大镜底下像直线；曲面在脚边像平面；神经网络在操作点附近像线性映射。于是：探针、一阶 steering、LoRA 低秩、都是「先当局部线性用」。自学时记住：**线性是工具，不是世界观**。离开局部，就要降 α 、换子空间、或承认模型失效。

图 0F-1 理论栈：从假设到动作



每一箭头都要有验证；跳过验证 = 把类比误当成定理。

读图：自学不要从最右直接背名词，要从左理解「为什么可以用线性工具」。

0F.8 理论-实验对照表（贴墙用）

说法	你至少要交出	常见过度解读
在流形上	ID/PR + 协议	神秘降维灵药
线性概念	探针 + 干预曲线	因果已证明
叠加	串扰或字典证据	不可解释宿命论
换内积	对照 G 的稳健性	任意新度量神话
推理廊道	逐步 AUC / 拉回	单一真路径

0F.9 自学讨论题（可写进笔记）

1. 若流形假设对某任务失败，你的工程策略怎么改？
2. 举一个「探针成功、steering 失败」的生活类比。

3. 为什么叠加会让「单一方向」故事变脆？
4. ID 下降而任务变难，是否矛盾？为什么？
5. 虚假推理对「只看答案的评测」提出什么警告？

0F.10 检查清单

- ☐ 能区分每个理论的主张/不主张
- ☐ 能为每个理论写出最小验证
- ☐ 能指出一种过度解读
- ☐ 理解局部线性是工具链中枢

§ 01 概述、版图与阅读地图

Overview, Landscape & Reading Map · RapidAi Research

大语言模型把离散 token 序列变成高维连续表示，再变回离散预测。流形视角要问的不是「模型像不像人」，而是：这些连续表示是否集中在远低于 ambient 维数的结构上？结构如何随层、随任务变化？我们能否测量、干预并据此做工程决策？

读前预备：建议已完成 §0A-§0C 检查清单，或确认自己能解释向量、余弦、残差流与下一 token 预测。

本章任务：建立全书对象表与问题清单，不引入重公式。

用 §0 的语言重说本章

四个对象 = 单张便签（点）、一堆同概念便签（集合）、旋钮方向、思考录像（轨迹）。六个问题 = 路薄不薄、局部能不能当平面、旋钮是否好用、尺子对不对、航道偏不偏、最后怎么变成工程旋钮/阈值/rank。

图 01-1 全书四个对象（先记图，再记公式）



读图：后面所有公式都在这四格里打转。说不清自己在研究哪一格，就先别写结论。

1.1 从三句黑话到四个对象

社区里常见三句话：

1. 「数据在流形上」；
2. 「概念是一个方向」；
3. 「推理是一条轨迹」。

本书把它们落实为四个可操作对象：

对象	符号	在 LLM 中的落点	典型问题
点（状态）	$h_{\ell,t} \in \mathbb{R}^d$	第 ℓ 层、位置 t 的残差流激活	读哪一层？哪个 token？
集合（支撑）	$\mathcal{S} \subset \mathbb{R}^d$	某语义/任务下激活的云与薄邻域	是否低维？几支？
方向/子空间	v_c, U_c	概念向量、可读出子空间	相关还是因果？
轨迹	$\tau = (h_0, \dots, h_T)$	层间路径或逐步 CoT 状态	对错能否早分？

最小符号表

$$h_{\ell,t} \in \mathbb{R}^d, \quad d_{\text{id}} \ll d, \quad v_c \in \mathbb{R}^d, \quad h' = h + \alpha \hat{v}_c, \quad \tau(x) = (h_t)_{t=0}^T$$

1.2 为什么 LLM 特别需要几何语言

统计学习已经给出泛化、过拟合、正则；信息论给出压缩与充分统计。几何语言补上的是**空间关系**：

- **邻近**：近义改写是否落到邻近激活？
- **方向**：概念变化是否沿近似线性方向？
- **维数**：有效自由度是否远小于 d ？
- **路径**：多步推理是否沿可监测轨迹前进？
- **干预**：沿某方向推一把，行为是否可预期改变？

对 Transformer，残差流提供一条自然的「状态空间」：每层都在改写同一个 d 维向量（每 token 一条）。于是「流形」不必悬空，而可以定义为：在选定 hook 协议下，数据诱导的经验测度所集中的低维支撑。

与经典流形学习的差别：经典方法常假设静态点云 $x_i \in \mathbb{R}^D$ ；LLM 中点云由模型 f_θ 动态产生，且依赖层、位置、提示模板与解码。协议不固定，几何结论不可比。

1.3 一张地图：从数据到 logits

生成式 LM 的几何流水线（示意）

$$\text{token ids} \xrightarrow{\text{embed}} E \xrightarrow{\text{blocks 1..L}} \{h_\ell\} \xrightarrow{\text{unembed}} \text{logits} \xrightarrow{\text{softmax}} p(\cdot \mid \text{context})$$

每一段都可以问几何问题：

- Embedding：词表点云的邻域是否反映共现/句法？
- 中层 h_ℓ ：是否出现语言无关的语义对齐？
- Unembedding：何种内积使「最近邻词」更有意义？
- 解码：轨迹是否掉出「合法续写」区域？

1.4 手册边界

维度	覆盖	不深挖
数学	工作定义、度量、ID、投影、简单黎曼直觉	完整微分几何证明体系
模型	Decoder-only Transformer 为主	全部架构/硬件内核
方法	探针、steering、ID、轨迹、SAE 入口	单篇论文全量复现
应用	可解释、对齐干预、RAG 诊断、PEFT 启发	合规审计全文

1.5 贯穿全书的六个问题

1. 观测与表示是否集中在低维结构上？ (§02, §05)
2. 局部能否用线性坐标（切空间）近似？ (§02, §03)
3. 概念是方向、子空间还是分叉子流形？ (§04)
4. 相似度该用哪种内积？ (§04)
5. 正确推理是否可分离、可早停？ (§06)
6. 几何量如何变成层、rank、阈值、门控？ (§07-§08)

热身思想实验 (无需 GPU)

想象只有 2 维隐藏状态。情感从负到正沿 x 轴，是否拒答沿 y 轴。那么「温和但拒答」是第二象限的点；steering「更安全」可能是加一段 $+\alpha e_y$ 。真实模型是高维版：轴不正交、会弯曲、还随层旋转--但你的实验问题仍是：轴在哪、弯多少、推一下是否到目标区域。

1.6 阅读路径与产物

- 先打基础：§02 + §02B（流形知识 x LLM 对照表）
- 再进表示：§03-§06
- 动手：§07 + §11

- 落地：§08-§10

学完最低交付：一层曲线图、一个带对照的方向、一条剂量曲线、一份失败反思（见序言）。

1.7 本章检查清单

- ☐ 能列出四个对象：点 / 集合 / 方向 / 轨迹
- ☐ 能说明「协议」（层、位置、模板）为何必须先冻结
- ☐ 能区分隐喻与可测指标
- ☐ 已选择自己的阅读路径 A/B/C

§ 02 流形、坐标、切空间与度量

Manifolds, Charts, Tangent Spaces & Metrics · RapidAi Research

本章把流形基础讲到「能和 LLM 激活对上话」：集合与维数、坐标图、切空间、度量与测地线、子流形与商空间直觉，以及噪声点云下的经验版本。每节都给出 **LLM 对照**，避免数学与模型脱节。


读前预备：掌握 §0A 的向量/内积/投影；知道 $\mathbb{R}^d$ 与子空间。若「同胚」「开集」陌生，可先把 chart 理解为「局部门牌号坐标系」，不影响抓主线。

读后应能：用自己的话解释维数、切空间、度量，并各举一个残差流例子。

2.0 直观热身：橘子皮与高速公路

- **橘子皮：**局部可撕成近似平面（二维），但全局是弯的闭合曲面--「局部欧氏、全局可弯」。
- **高速公路网：**你人在路面（低维约束）上移动；直升机直线距离是 ambient 弦长，开车里程才是 on-manifold 距离。
- **LLM：**激活活在 $\mathbb{R}^d$ (ambient)，但合法语义可能只占薄薄的「路面」；乱 steering 就像直升机抄近路掉进山谷（乱码）。

图 02-1 流形：局部像平地，全局可以弯曲；弦长 != 路面距离



读图：激活向量住在大房间 $\mathbb{R}^d$ 里，但有效状态可能只在弯曲薄板上。两点「向量差很小」不等于沿合法语义改写走近。

形式定义 流形 (工作级) M 每点有邻域同胚于 $\mathbb{R}^k$; $k = \dim M$。可嵌入 ambient $\mathbb{R}^d$, $k \ll d$。	物理直觉 大房间里的弯曲路面 房间=$\mathbb{R}^d$; 路面=有效状态。局部像平地, 整体可弯可分叉。掉到泥土里~=乱码/离流形。
形式定义 切空间与弦长/测地 $T_p M$ 为 p 处一阶线性空间; 弦长 $\ p - q\$ vs $\text{dist}_M = \inf \text{Len}(\gamma)$。	物理直觉 山坡木板 · 直升机 vs 盘山路 木板=局部一阶近似 (小步 steering 的舞台); 直升机直线=向量差; 盘山路=沿合法语义走的距离。
Ambient 空间 坐标所在的大空间 $\mathbb{R}^d$, 如 hidden size=4096。	流形 M 局部像 $\mathbb{R}^k$ 的集合, $k \ll d$ 时称低维结构。
坐标图 chart 给流形一块区域门牌号 (局部坐标)。	切空间 在某点贴一块「最佳平面」, 一阶近似用的线性空间。
度量 如何量长度与角度 (欧氏 / 白化 / 因果内积)。	经验点云 真实数据是带噪声的有限样本, 不是干净曲面。

2.1 为什么先学这些

若直接从 steering 向量开始, 很容易把任何均值差都叫做「概念方向」。基础部分要训练一种纪律: 先问对象在哪个空间、用什么坐标、距离如何定义、局部线性近似的范围有多大。只有这些清楚, §03 以后的层曲线、ID、因果干预才有意义。

学习目标: 读完本章, 你能用自己的话解释: 流形维数、图表 (atlas)、切空间、黎曼度量、测地距离, 并各举一个 LLM 残差流中的类比。

2.2 从集到「局部像欧氏空间」

欧氏空间 $\mathbb{R}^k$ 是最简单的 k 维模型空间: 全局一套笛卡尔坐标。流形保留「局部像 $\mathbb{R}^k$ 」, 但允许全局弯曲、空洞或多种粘合方式。

拓扑流形 (工作表述)

M 为第二可数的 Hausdorff 空间。若存在整数 $k \geq 0$, 使得每点 $p \in M$ 都有邻域 U 与同胚

$$\varphi : U \xrightarrow{\sim} \varphi(U) \subset \mathbb{R}^k,$$

则称 M 为 k 维拓扑流形； φ 称为**坐标图 (chart)**， (U, φ) 覆盖的汇集称为**图册 (atlas)**。

- $k = 0$: 离散点； $k = 1$: 曲线； $k = 2$: 曲面；.....
- 球面 S^2 不能只用一张全局坐标无奇点覆盖，但可用两张图（如南北极投影）。
- 线性子空间 $\mathbb{R}^k \subset \mathbb{R}^d$ 是「平坦流形」--流形不必弯曲。

LLM 对照 · 多义词分支

单词 "bank" 的上下文激活可能落在「河岸」与「银行」两片区域。全局强行用一个线性坐标解释会混杂；更像需要两张局部图，或一个不连通的支撑。这就是 atlas / 多分支思想在表示空间中的影子。

2.3 光滑结构与坐标变换

若两张图重叠，坐标变换

$$\psi \circ \varphi^{-1} : \varphi(U \cap V) \rightarrow \psi(U \cap V)$$

为 C^∞ （或至少 C^1 ），则可以说切空间、导数与向量场。LLM 分析几乎从不显式构造 atlas，但「换一层 / 换 hook 点 / 换白化坐标」本质上就是在换一套坐标，变换是否近似线性、是否稳定，决定了方向能否迁移。

局部坐标中的点

$$p \mapsto (x^1(p), \dots, x^k(p)) \in \mathbb{R}^k$$

在 LLM 中，最常用的「坐标」常常就是 ambient 的 d 个神经元轴，或 PCA/白化后的主成分轴。后者往往更接近「有效坐标」。

2.4 切空间：局部线性化

曲线 $\gamma : (-\varepsilon, \varepsilon) \rightarrow M$ ， $\gamma(0) = p$ ，其速度 $\dot{\gamma}(0)$ 称为 p 处的切向量。全体切向量构成切空间 $T_p M \cong \mathbb{R}^k$ 。

一阶近似

$$\gamma(t) \approx p + t v, \quad v \in T_p M$$

在嵌入于 $\mathbb{R}^d$ 的子流形上, $T_p M$ 可看成 $\mathbb{R}^d$ 中的 k 维线性子空间。

为何对 LLM 关键：线性探针、diff-in-means、一阶 steering 都是在说：在某个操作点附近，概念变化落在一个低维切方向上。LRH 的强形式声称「很多概念的切方向在大范围内近似恒定」，这是额外假设，不是流形定义的一部分。

局部 vs 全局：切空间只保证无穷小邻域的线性像。 α 很大的 steering 可能离开合法区域，表现为乱码或行为崩坏--这不是「方向错了」的唯一解释，也可能是「走太远，一阶近似失效」。

2.5 度量、长度与角度

仅有光滑结构还不能谈「多远」「多正交」。需要在每个切空间上指定内积，即黎曼度量 g ：

$$\langle u, v \rangle_p = g_p(u, v), \quad \|u\|_p = \sqrt{\langle u, u \rangle_p}.$$

曲线长度与流形距离：

$$\text{Len}(\gamma) = \int_a^b \|\dot{\gamma}(t)\|_{\gamma(t)} dt, \quad \text{dist}_M(p, q) = \inf_{\gamma: p \rightarrow q} \text{Len}(\gamma).$$

欧氏弦长 $\|p - q\|_2$ (把 M 嵌入 $\mathbb{R}^d$ 后) 一般**不等于** $\text{dist}_M(p, q)$ 。瑞士卷两点在 3D 很近，沿卷面可能很远。

LLM 对照 · 余弦 vs 语义路径

两个句子的激活余弦很高，只说明在当前内积下方向接近；它们在「语义流形」上的路径距离是否短，取决于是否存在一串合法改写把一句连续变到另一句，且轨迹始终留在高密度区域。这就是为何只报余弦往往不够，还要看插值是否可读、是否保持语法。

2.6 常用度量选择 (进入 LLM 实验)

度量	定义要点	常见用途	风险
欧氏 / 余弦	$G = I$	默认基线、层扫	尺度与各向异性未校准
马氏 / 白化	$G = \hat{\Sigma}^{-1}$	去相关、比方向	协方差估计需足够样本
unembed 度量	与输出词嵌入相关	词空间解释	不一定适合中层语义
因果内积 (§04)	为可加概念而设	多概念 steering	估计与验证成本高

$$\langle u, v \rangle_G = u^\top G v, \quad \cos_G(u, v) = \frac{u^\top G v}{\sqrt{u^\top G u} \sqrt{v^\top G v}}$$

2.7 子流形、积与「并」

- **子流形**：嵌入在更高维空间中的低维流形，如 $S^1 \subset \mathbb{R}^2$ 。激活云常被建模为 $\mathbb{R}^d$ 中的子流形（加噪声）。
- **积流形**： $M \times N$ ，维数相加。多因素语义（话题 $\times$ 情感 $\times$ 语言）有时近似「因子近似独立」的积结构。
- **流形并**：多个片断粘在一起；数据经常是「分层流形 / 流形并」，不是单一连通组件。

LLM 中：不同领域、语言、任务可能对应不同分支；强行单一高斯或单一 PCA 子空间会抹平结构。

2.8 噪声点云：从理想流形到经验测度

真实数据是样本 $\{x_i\}$ ，不是干净的 M 。更诚实的模型是

$$x_i = i(z_i) + \varepsilon_i, \quad z_i \in \mathcal{M}, \quad \varepsilon_i \sim \text{噪声}$$

于是我们估计的是**经验几何**：邻域图、协方差谱、ID、密度等高线。样本量、噪声水平、采样偏差会改变所有曲线。

$$\mathcal{D} = \{h_{\ell, t^*}(x) \mid x \in \mathcal{X}\}$$

必须固定：模型 θ 、层 ℓ 、位置规则 t^* 、模板、精度、是否 LN 后。改任一条件， $\mathcal{D}$ 就换了。

2.9 维数的三种面孔

名称	含义	LLM 例子
Ambient dim d	坐标个数	hidden size 4096
Manifold dim k	局部自由度	理想语义因子数
Effective rank / d_{id}	可估的有效维	PR、TwoNN、PCA95%

k 是理论对象； d_{id} 是估计量。永远同时报告 ambient d 与估计有效维，避免「ID=40」这种缺参照的句子。

2.10 指数映射与「走一步」的直觉

在 p 沿切向量 v 走一小步，理想化写作 $\exp_p(tv)$ 。在嵌入坐标里，小步近似 $p + tv$ 。LLM 的

$$h' = h + \alpha \hat{v}$$

正是嵌入空间中的欧氏一步。它是否近似「沿流形的一步」，取决于 v 是否切于数据支撑，以及 α 是否足够小。这为后文剂量曲线与离流形崩坏提供语言。

2.11 迷思澄清（基础版）

- 流形 != 一定弯曲；子空间是平坦流形。
- 降到 2D 的图 != 真实边界。
- 余弦高 != 语义可互相改写。
- ID 低 != 信息少；可能是高效压缩。
- 有坐标轴 != 轴有类可命名意义。

自学加餐·流形（具体场景）

用二维记录「情绪强度 x 、正式程度 y 」。真实句子可能落在一条弯带子附近，而不是填满正方形。带子 = 语义流形玩具版。

1. 互改是否合法：看沿带子走是否仍像人话，不是只看直线距离。
2. 切线：小步改写约沿切线；大步可能离开带子。
3. 换尺子：心理上的「同样礼貌」距离，可能与欧氏距离不一致。

2.12 本章检查清单

- [] 能解释 chart / atlas / 切空间 / 度量
- [] 能区分弦长与 on-manifold 距离
- [] 能写出 LLM 点云的协议 $\mathcal{D}$
- [] 能区分 d 、 k 、 d_{id}
- [] 能说明为何大 α 会使一阶近似失效

§ 02B 流形学习方法及其在 LLM 中的含义

Manifold Learning Methods <-> Large Language Models · RapidAi Research

经典流形学习给出一组「从点云恢复结构」的算法。LLM 研究很少原样照搬整条算法链，但几乎每一条的**守恒量与失败模式**都会在激活分析里重现。本章按方法给出：原理 -> 公式 -> 适用 -> 在 LLM 中的正确/错误用法。

读前预备：§0A.8-0A.9 (SVD/PCA)、§02 的距离与邻域直觉。

阅读技巧：不要试图实现所有算法；优先记住「每个方法守恒什么 + 在 LLM 中的误用」。

2B.0 一张图抓住重点

点云进来之后，你要么（1）看全局线性结构（PCA），要么（2）建邻域图再谈路径（Isomap 思想），要么（3）只做可视化（UMAP）。LLM 工作流推荐：**PCA/PR -> 邻域纯度 -> 探针 -> 干预 -> (可选) 字典学习**；可视化最后才做。

2B.1 总对照表

方法	它试图保持什么	在 LLM 中的有益用法	常见误用
PCA / SVD	全局方差能量	有效秩、白化、读出子空间	把前两主成分当语义真理
MDS	两两距离	小样本概念距离检查	高维噪声距离直接当语义
Isomap	测地距离（邻域图最短路径）	思考「合法改写路径」	在多簇激活上强行单流形
LLE	局部线性重建权	理解局部切空间/补丁	密度不均时硬套默认 k
Laplacian Eigenmaps	局部邻接的平滑	聚类、半监督标签传播直觉	把特征向量直接当概念名
Diffusion Maps	扩散距离 / 多尺度几何	多尺度主题结构	参数敏感却不报告
t-SNE / UMAP	局部邻域可视化	沟通用附图	当定量证据

方法	它试图保持什么	在 LLM 中的有益用法	常见误用
自编码器 / SAE	重建 + 结构约束	字典特征、可解释原子	无因果验证的「自动发现」

2B.2 PCA / SVD：平坦近似的第一工具

对中心化数据矩阵 $X \in \mathbb{R}^{n \times d}$,

$$X = U\Sigma V^\top, \quad \hat{\Sigma} \approx \frac{1}{n-1} X^\top X.$$

主成分是方差最大的正交方向。能量维与参与比见 §05。

LLM 用法

- 对某层激活做 PCA, 看 $r_{0.95}$ 是否 $\ll d$;
- 在 PCA 坐标中做探针, 检查是否少数分量可解释任务;
- 对差分矩阵 ΔH 做 PCA, 启发 LoRA rank。

不要：把 PC1-PC2 散点图的「好看分簇」写成机制结论。

2B.3 邻域图、Isomap 与测地直觉

Isomap：在点云上连 k NN 边，边权为欧氏距离，用图最短路近似测地距离，再 MDS 嵌入。

$$\widehat{\text{dist}}_M(i, j) = \text{ShortestPath}_{G_k}(i, j)$$

迁移到 LLM 的正确问题不是「把激活跑一遍 Isomap」，而是：

- 两激活之间是否存在一串**合法上下文改写**形成路径？
- 插值 $h(\alpha) = (1 - \alpha)h_0 + \alpha h_1$ 是否在中间保持语法/主题？（欧氏捷径可能穿洞）

多簇警告：若激活来自多个不相交领域，邻域图会桥接错误或断裂。先聚类/分层，再谈单流形测地。

2B.4 LLE：局部切空间的算法版

LLE 假设点可由邻域线性重建：

$$\min_W \sum_i \left\| x_i - \sum_{j \in \mathcal{N}(i)} W_{ij} x_j \right\|^2 \quad (\sum_j W_{ij} = 1)$$

再在低维坐标中保持相同 W 。直觉：每个局部补丁是切空间上的仿射组合。

LLM 对照：对同一概念的一组改写句，检查局部 PCA 维数是否稳定；若局部 $k \approx 1$ ，单方向近似更可信；若局部 k 很大，说明概念条件化强烈，需要子空间或分簇方向。

2B.5 Laplacian 与平滑先验

图拉普拉斯 $L = D - A$ （或归一化版本）的小特征向量在图上平滑。这对应：标签/概念分数应在邻域内缓变。线性探针可看成极简读出；Laplacian 正则则鼓励邻域一致。

$$\sum_{i \sim j} A_{ij} (f_i - f_j)^2 = f^\top L f$$

在 LLM 中：若两个激活邻居在表示空间很近，但其毒性标签相反，要么邻域度量错了，要么模型用了你度量没抓住的细方向。

2B.6 扩散几何：多尺度

扩散地图用随机游走功率 P^t 在不同时间尺度探查几何。小 t 看局部，大 t 看全局连通。主题结构、语言簇、任务簇可能出现在不同尺度--这提醒我们：只报一个 k NN 的 ID 或一个 UMAP 是片面的。

2B.7 可视化嵌入：只能当附图

t-SNE / UMAP 优化的是局部邻域保持的可视化目标，**全局距离、簇大小、空隙**都可能被扭曲。

可以	不可以
展示「似乎出现两簇」的动机	用簇间距证明因果
辅助挑选要人工读的样本	用颜色分离代替 AUC
与定量曲线并排	只丢一张图当结论

2B.8 自编码器与 SAE：学坐标，而不是画坐标

经典 AE 学习 $f: x \mapsto z \mapsto \hat{x}$ 。稀疏自编码器在 LLM 激活上学习过完备字典 (§09)。几何上，字典原子提供一组「可能的轴」。但轴的可解释性必须靠激发样例 + 干预验证，而不是靠重建误差单独证明。

$$h \approx Df + \eta, \quad f \text{ 稀疏}$$

2B.9 把经典方法嵌入 LLM 工作流（推荐顺序）

1. 协议冻结 -> 收集 $\mathcal{D}$ (§02.8)
2. PCA / PR / 谱 -> 有效维与各向异性
3. 邻域纯度 / kNN -> 局部语义一致性
4. 探针与 diff-in-means -> 可读性
5. 干预 -> 因果
6. (可选) SAE / 扩散 / Isomap 思想 -> 细结构与路径
7. 可视化 -> 沟通

最小定量组合（入门就够）

$$(\text{PR}(\ell), \text{Purity}@k(\ell), \text{Acc}_{\text{probe}}(\ell), \Delta(\alpha))$$

2B.10 与 LLM 特有结构的接口

- 层：每一层一个点云，曲线比单点重要；
- 位置：最后 token != 平均池化；
- 提示模板：模板是坐标变换的一部分；
- 解码：温度、top-p 改变轨迹采样，不改变单次前向点，但改变「推理流形」的经验覆盖；
- 词表：unembedding 把几何接到离散符号。

课堂级演示（CPU 也可做玩具版）

用小模型或随机投影把激活降到 64 维后：计算 PR；用 200 条正负句做 diff-in-means；报探针 Acc 与随机标签 Acc。再画 UMAP 作附图。用这套三联证明「方法链」，不必一上来全量 SAE。

2B.11 本章检查清单

- [] 能说出至少 5 种方法各自守恒什么
- [] 能指出 UMAP 的合法/非法用法
- [] 能写出 LLM 点云分析的推荐顺序
- [] 能解释为何 Isomap 的「路径」思想比「跑通软件」更重要

- [] 能把 PCA 有效秩连到 LoRA rank 启发 (细节见 §05)

§ 03 表示空间、残差流与语义流形

Representation Space, Residual Stream & Semantic Manifolds · RapidAi Research

有了流形基础，我们进入 Transformer 内部：点落在哪里、集合如何随层演化、语义邻域怎样度量。本章建立「残差流 = 状态空间」的工作图景，并给出可计算的邻域与轨迹指标。

读前预备：§0C (Transformer 数据流)、§02.8 (协议化点云)、§0A 投影与余弦。

关键词： $h_{\ell,t}$ 、hook、最后 token、Purity@k、层间轨迹。

3.0 先建立心智模型

把一次前向想成：每个 token 带着一个 d 维「便签」走进网络；每层 attn 允许它读别人的便签，MLP 在自己的便签上写新特征；最终最后一层便签被翻译成词表概率。几何分析就是在**约定位置把便签抽出来**做测量。

图 03-1 语义邻域：近义改写应靠近，干扰项应拉开



指标：Purity@k up · 类内/类间比 R down · 线性探针 Acc up (随层画曲线)

读图：不要只看 UMAP 好不好看。用 Purity 与探针把「是否成团、是否可分」变成数字，再比较不同层。

形式定义

语义流形与邻域指标

$\mathcal{S}_c = \{h_{\ell,t^*}(x) : x \models c\}$; Purity@k; 类内/类间比 R 。

物理直觉

地图上的兴趣点云

「都在说同一概念」的状态应抱团；干扰项应在另一片。Purity=邻居是不是自己人；不要只看 UMAP 好不好看。

$h_{\ell,t}$

第 ℓ 层、位置 t 的状态向量。协议四元组之一。

语义流形 $\mathcal{S}_c$

表达概念 c 的激活集合的薄支撑（工作定义）。

3.1 残差流作为状态空间

Decoder-only 块（示意）把同一通道上的状态不断改写：

$$x_{\ell+1} = x_{\ell} + \text{Attn}_{\ell}(x_{\ell}) + \text{MLP}_{\ell}(x_{\ell} + \text{Attn}_{\ell}(x_{\ell}))$$

几何解读：

- $x_{\ell} \in \mathbb{R}^d$ 是位置上的状态点；
- Attn / MLP 是两次增量，相对步长 $\delta_{\ell} = \|x_{\ell+1} - x_{\ell}\| / \|x_{\ell}\|$ 常小于 1；
- Pre-LN / Post-LN 改变「在哪一点读向量」--hook 协议必须写进实验。

纪律： 不先固定 (ℓ, t, hook) ，就不要比较「概念是否线性」。

3.2 嵌入、位置与词表几何

对象	位置	几何角色
Token embedding	输入	词表点云；共现邻域
位置编码 / RoPE	注意力内部	相对位置进入内积
$h_{\ell,t}$	第 ℓ 层	上下文条件化状态
Unembedding	输出	映回词表方向 / logits

RoPE 等使「同一内容、不同位置」的可比性变复杂：比较激活时要说明是否已剥离位置影响，或只在固定相对位置协议下比较。

3.3 注意力：点云上的数据依赖搬运

$$Q = XW_Q, K = XW_K, V = XW_V$$

$$\text{Attn}(X) = \text{softmax}\left(\frac{QK^{\top}}{\sqrt{d_k}} + M\right)V$$

每一行是对 value 的凸组合（有 mask 时在允许集合上）。头（head）可特化：位置、指代、归纳头等。几何上，注意力改变的是「信息从哪些点汇入当前点」，从而把序列结构写进状态。

3.4 MLP：特征扩张与写回

$$\text{MLP}(h) = W_2 \sigma(W_1 h + b_1) + b_2$$

$d_{\text{ff}} \gg d$ 提供超完备特征容量，与叠加假说 (§04) 相连。许多「细特征」可能在 MLP 神经元或 SAE 原子上更清晰，而不是在残差的任意轴上。

3.5 语义流形：工作定义

在固定协议下，概念 c 的经验支撑

$$\mathcal{S}_c = \overline{\{h_{\ell, t^*}(x) : x \text{ 表达 } c\}}$$

及其 ε -邻域，称为 c 的语义流形（工作定义）。它可能是：近似线性；弯曲子流形；多分支并。

操作化问题清单

1. 同义改写是否减小 $\|h(x) - h(x')\|$ 或提高 $\cos$?
2. 线性插值中点是否仍解码为「中间语义」?
3. 跨语言同义是否在中层更靠近（语言无关子空间）?
4. 负样例（形式相似但语义不同）是否被拉开?

3.6 邻域与可分性指标

类内/类间比与 kNN 纯度

$$R = \frac{\mathbb{E}_{h, h' \in S_c} \|h - h'\|}{\mathbb{E}_{c \neq c'} \mathbb{E}_{h \in S_c, h' \in S_{c'}} \|h - h'\|}$$
$$\text{Purity}@k = \frac{1}{n} \sum_i \frac{|\{j \in \mathcal{N}_k(i) : y_j = y_i\}|}{k}$$

同时报告线性探针 $\text{Acc}(\ell)$ 。三者随层曲线构成「表示质量」的最小仪表盘。

3.7 层间轨迹

$$\delta_\ell = \frac{\|h_{\ell+1} - h_\ell\|}{\|h_\ell\|}, \quad a_\ell = \cos(h_\ell, h_L), \quad p_\ell(v) = \frac{h_\ell^\top v}{\|v\|}$$

用途：定位信息写入层；发现突变；为 §06 的失败分岔提供信号。

3.8 池化与位置选择

选择	适用	注意
最后 token	因果 LM 决策点	最常用默认
答案跨度均值	抽取/填空	对齐分词
全序列均值	粗文档嵌入	稀释关键 token
专用哨兵 token	提示工程	哨兵本身改变几何

3.9 与 §02 基础的显式连接

- 层 ℓ 的激活云 = 经验点云 $\mathcal{D}_\ell$;
- 局部 PCA 维 = 切空间维数的粗估;
- 余弦 = 选定度量下的角度;
- 插值穿洞 = 弦长捷径 != 测地路径;
- 多领域混合 = 流形并, 需先分层。

3.10 迷你实验协议

1. 选 300-1000 对近义改写 + 300 个干扰项;
2. 钩每层最后 token;
3. 画 Purity@10(ℓ)、探针 Acc、PR (§05) ;
4. 对最佳层做 10 条插值人工阅读;
5. 记录模板与种子。

自学加餐·表示几何（具体）

把同一意思的 20 种说法丢进模型，取出某层最后 token 便签：

1. 若它们在空间里抱成团，而「形似义不同」的干扰句在团外，说明语义邻域健康。
2. 层曲线：中层团更紧、输出层更任务化，是常见现象，需你自己的图说话。

3. 插值实验：两端是人话，中点崩溃 = 弦长穿洞，提醒流形不是整个欧氏空间。

3.11 检查清单

- ☐ 协议四元组：模型 / 层 / 位置 / hook
- ☐ 至少两种定量邻域指标
- ☐ 可视化仅附图
- ☐ 写明度量 G

§ 04 线性表示、概念方向与因果内积

Linear Representations, Concept Directions & Causal Inner Products · RapidAi Research

流形说明「状态住在低维结构里」；线性表示假设 (LRH) 进一步猜测：许多人类概念在该结构上的变化，可用单一方向（或低维子空间）近似，并且沿该方向的加性干预具有因果效应。本章给出定义、估计、因果验证与内积选择。

读前预备：§0A.5 投影；§0B 的 held-out 与随机基线；§02.4 切空间（局部线性）。

一句话：探针证明「看得见」，steering/消融证明「推得动」。

4.0 入门故事：调味旋钮

想象表示空间里有一个「甜度」旋钮方向 v 。读出：看当前状态在旋钮上的刻度 $\langle h, \hat{v} \rangle$ 。调节： $h \leftarrow h + \alpha \hat{v}$ 增加甜度。若旋钮与「辣度」缠在一起（叠加），你一拧甜度辣度也变--这就是串扰。LRH 研究的是：哪些味道有近似独立的旋钮，旋钮在哪一层，拧多少会坏菜。

图 04-1 相关（探针）vs 因果（steering 剂量曲线）


只证明「看得见」

线性探针 Acc 高
diff-in-means 可分
-> 相关 / 可读出

还不能说「推动这个方向
就会改变行为」

还要证明「推得动」

Delta(alpha) 真方向



读图：左半边再漂亮也只是相关。右半边：真方向应随 alpha 出现剂量效应，且明显高于随机方向。崩坏区（alpha 太大曲线乱掉）不要吹成成功。

形式定义

LRH 与干预

存在 v_c : $s = \langle h, v_c \rangle$ 与概念相关，且 $\exists I$ 使
 $\alpha \in I \Rightarrow \Delta(\alpha) > \Delta_{\text{rand}} + \delta$ 。

物理直觉

调味旋钮·扳道岔

看指针=相关/读出；拧旋钮且菜变味=因果。随机乱拧作对照。alpha 太大掀锅!=成功。多旋钮咬合=叠加串扰。

LRH

概念变化可用方向/低维子空间近似，并可干预。

Diff-in-means

正类均值减负类均值，最强基线之一。

剂量曲线 Delta(alpha)

干预强度扫描；必须带随机对照。

叠加 superposition

多特征挤在有限方向上，导致串扰。

4.1 从切空间到「全局近似恒定的方向」

§02 只保证局部线性。LRH 的额外主张是：对概念 c ，存在 v_c ，在感兴趣的上下文集合 $\mathcal{X}_c$ 上，

$$s_c(h) = \langle h, v_c \rangle \quad \text{与「是否表达 } c \text{」单调相关}$$

$$h' = h + \alpha \hat{v}_c \quad \text{能系统改变与 } c \text{ 相关的行为}$$

弱形式：局部子空间；强形式：单方向、跨上下文可迁移。写论文或做工程时要声明你用的是哪一种。

4.2 估计 v_c

Diff-in-means

$$v_c = \mathbb{E}[h \mid c+] - \mathbb{E}[h \mid c-]$$

线性探针

$$\min_{w,b} \mathbb{E}[\ell(\sigma(w^\top h + b), y)] + \lambda \|w\|_2^2$$

方法	优点	风险
Diff-in-means	强基线、实现简单	混杂进入方向
探针权重	有 held-out 指标	相关!=因果
对比 PCA / CTA	多方向	配对质量
SAE 原子	细粒度	训练与对齐成本
梯度归因	贴近损失	局部噪声

```
v = mean(H_pos, 0) - mean(H_neg, 0)
v = v / (np.linalg.norm(v) + 1e-12)
H2 = H + alpha * v    # steering
```

4.3 投影、消融与剂量

$$\text{proj}_v h = \frac{\langle h, v \rangle}{\langle v, v \rangle} v, \quad h_{\text{ablate}} = h - \text{proj}_v h, \quad h' = h + \alpha \hat{v}$$

$$\Delta(\alpha) = J(h + \alpha \hat{v}_c) - J(h), \quad \Delta_{\text{rand}}(\alpha) = J(h + \alpha \hat{u}) - J(h)$$

有效性：存在区间 I 使 $\alpha \in I \Rightarrow \Delta(\alpha) > \Delta_{\text{rand}}(\alpha) + \delta$ ，且崩坏边界外的点不计入「成功」。

情感方向迷你协议

1. 构造正/负产品评论各 2000 条；held-out 1000；
2. 取中间层最后 token；diff-in-means；
3. 探针 Acc；随机标签探针；
4. $\alpha \in \{-2, -1, 0, 0.5, 1, 2\}$ 扫续写情感分数；
5. 报告对照方向与流畅度惩罚。

4.4 子空间版 LRH

若概念条件化强，用 $U_c \in \mathbb{R}^{d \times r}$ ：

$$h' = h + U_c \beta, \quad h_{\text{ablate}} = (I - U_c U_c^+) h$$

局部 PCA 维 (§02B LLE/PCA 思想) 可启发 r 。

4.5 因果内积

欧氏点积不一定匹配「概念可加」。设 $G \succ 0$ ：

$$\langle u, v \rangle_* = u^\top G v, \quad \cos_*(u, v) = \frac{u^\top G v}{\sqrt{u^\top G u} \sqrt{v^\top G v}}$$

目标：多概念方向更正交、类比算术更稳、联合 steering 串扰更小。工程近似：白化 $G = \hat{\Sigma}^{-1}$ ；或与 unembedding 相关的度量。关键是**报告** G 并做稳健性检查。

类比可测化

4.6 叠加

$$h \approx Df + \eta, \quad f \text{ 稀疏}, \quad m = \# \text{features} \gg d$$

后果：单方向纠缠；强 α 误伤；需要 SAE、分簇或子空间。

4.7 反模式

- 十几条手工句发布「通用安全方向」；
- 训练分布上夸大泛化；
- 把崩坏当「控制成功」；
- 层与内积不声明。

自学加餐·LRH（三档声明）

1. 可读：探针/AUC 高（温度计）。
2. 可推：存在 α 区间击败随机（真拧暖风）。
3. 可迁移：换模板/轻微 OOD 仍成立（换房间还暖）。

写报告必须声明自己在哪一档。很多材料停在（1）却写成（3）。

4.8 检查清单

- [] 正负样本与混杂
- [] held-out + 随机对照
- [] α 曲线而非单点
- [] 声明弱/强 LRH 与 G

§ 05 内在维度、谱与冗余

Intrinsic Dimension, Spectra & Redundancy · RapidAi Research

流形假设若要对实验有用，必须落到可计算的「有效维数」。本章系统介绍参与比、PCA 能量维、TwoNN 与 MLE 等估计量，说明如何解读层间曲线，以及如何把有效秩启发连接到 LoRA rank、剪枝与蒸馏。始终牢记：估计的是经验点云几何，不是神秘的「模型智商」。

读前预备：§0A.8-0A.9（特征值/PCA）、§0B.5（高维近邻陷阱）、§02.9（三种维数）。


记忆口诀：先扫 PR（快），再点查 TwoNN（慢），趋势一致才下笔。

5.0 入门类比：压缩文件与有效通道

一张 4096 维的「便签」若大部分方向几乎不用，就像 BMP 变成 PNG：名义像素很多，有效信息维更低。PR / $r_{0.95}$ 估的是「还有多少条有效通道在冒泡」。但注意：压缩得好 != 任务简单；有时任务把点云重新「撑开」。

图 05-1 名义维 d vs 有效维：能量堆在前几根轴上

特征值 λ (方差能量)



读图：左边很高的柱子拿走了大部分方差。有效维是「还需要几根柱子才能盖住 95% 能量」，不是 UMAP 画成 2 维就叫 ID=2。

形式定义

有效维

d_{ambient} ; $PR = (\sum \lambda_i)^2 / \sum \lambda_i^2$; r_r 累计方差阈值维; TwoNN 等估 d_{id} 。

物理直觉

房间很大，人只在地毯上活动

d =房间面积; PR/r_r =还需要几条通道冒泡。瘦高天际线=低有效维; 平顶城市=高有效维。趋势重于绝对小数。

Ambient d

坐标个数=hidden size。

PR 参与比

谱能量分散程度的快指标。

r_tau 能量维

累计方差过阈值所需主成分数。

TwoNN ID

用最近邻距离比估局部维，慢但互补。

5.1 三种维数，三种叙事

名称	符号	含义	LLM 例子
Ambient dimension	d	坐标个数	hidden size = 4096
Manifold dimension	k	局部真实自由度	理想语义因子数
Estimated ID / rank	$d_{\text{id}}, r_{\tau}, \text{PR}$	可计算代理	TwoNN、PCA95%、参与比

表述纪律：永远同时报告 ambient d 与估计量。只说「ID=40」而没有 d 、没有协议，等于没说。

从 §02 的噪声模型出发，样本来自

$$h = i(z) + \varepsilon, \quad z \in \mathcal{M}^k, \quad h \in \mathbb{R}^d.$$

ID 估计试图从有限 $\{h_i\}$ 恢复 k 的代理。噪声、有限样本、多分支混合都会让代理偏离 k —所以我们更信任**相对趋势**（跨层、跨数据、跨模型），而不是小数点后三位。

5.2 谱方法家族：PR 与能量维

对中心化激活 $X \in \mathbb{R}^{n \times d}$ ，样本协方差特征值 $\lambda_1 \geq \dots \geq \lambda_d \geq 0$ 。

Participation Ratio（参与比）

$$\text{PR} = \frac{\left(\sum_{i=1}^d \lambda_i\right)^2}{\sum_{i=1}^d \lambda_i^2}$$

谱均匀时 $\text{PR} \rightarrow d$ ；能量集中在少数方向时 PR 显著变小。计算便宜，适合全层扫描。

PCA 能量维

$$r_\tau = \min \left\{ r : \frac{\sum_{i=1}^r \lambda_i}{\sum_{i=1}^d \lambda_i} \geq \tau \right\}, \quad \tau \in \{0.90, 0.95, 0.99\}$$

```
# 快速实现对照 (不渲染 TeX)
cov = (X.T @ X) / max(n - 1, 1) # X mean-centered
evals = np.clip(np.linalg.eigvalsh(cov), 0, None)
PR = (evals.sum()**2) / (np.square(evals).sum() + 1e-12)
tau = 0.95
cume = np.cumsum(evals[::-1])[::-1] # if ascending eigvalsh
# 更直观: 排序降序后再 cumsum
evals_desc = evals[::-1]
frac = np.cumsum(evals_desc) / (evals_desc.sum() + 1e-12)
r95 = int(np.searchsorted(frac, 0.95) + 1)
```

5.3 邻域方法家族: TwoNN 与 MLE

TwoNN (Facco 等思想)

对每点取最近邻距 r_1 、次近邻距 r_2 , $\mu = r_2/r_1 > 1$ 。理想均匀采样于 k 维流形时,

$$d_{\text{id}} \approx \frac{n}{\sum_{i=1}^n \log \mu_i}.$$

局部 MLE (Levina-Bickel 风格)

$$\hat{m}_k(x) = \left(\frac{1}{k-1} \sum_{j=1}^{k-1} \log \frac{T_k(x)}{T_j(x)} \right)^{-1}$$

$T_j(x)$ 为到第 j 近邻的距离; 再对样本与 k 聚合 (中位数更稳健)。

邻域法对重复点、近重复句子、规范化方式敏感: 先去重、再固定距离度量。

实践建议

- 先报 $\text{PR} / r_{0.95}$ (稳、快);
- 再在关键层补 TwoNN 或 MLE;
- 若两者趋势一致, 才写「有效维下降/上升」;
- 分支混合会抬高 ID: 按领域/语言分层后再估。

5.4 如何读层间 ID / PR 曲线

1. **早期上升**: 上下文混合、特征展开;
2. **中部平台或峰值**: 表示较「铺开」, 常适合多样概念探测;
3. **近输出下降**: 向 logits 压缩, 任务相关;
4. **异常尖峰或塌缩**: 检查位置协议、坏点、层数值问题。

把探针 Acc 曲线叠在同一张图: 有时 $\ell_p = \arg \max \text{Acc}$ 与 PR 峰值层不同--读出最佳层不必等于「最铺开」层, 干预层 ℓ_s 又可能不同 (§07)。

实验日志模板 (可直接粘贴)

```
model=..., d=..., pos=last_content_token, n=..., dtype=bf16, hook=residual_post_MLP,
metric=G=I。
```

```
PR peak layer=l*, PR(l*)=...; TwoNN median(l*)=...; probe best=l_p, Acc=...; notes=...
```

5.5 差分谱与 LoRA rank 启发

微调、偏好对齐或领域适应前后, 收集同输入集合的激活, 形成差分:

$$\Delta H = H_{\text{after}} - H_{\text{before}}.$$

对 ΔH 估 $\hat{r} = r_{0.95}(\Delta H)$ 或 $\text{PR}(\Delta H)$ 。LoRA rank 搜索网格可取

$$r \in \{\lceil \hat{r}/2 \rceil, \hat{r}, 2\hat{r}\} \cap \mathbb{Z}_{>0}.$$

这是数量级启发, 不是定理。 必须在下游指标上做消融; 不同模块 (attn q/v vs mlp) 的有效秩可以不同, 宜分别估计。

5.6 冗余、剪枝、量化与蒸馏

- **冗余**: $d_{\text{id}} \ll d$ 暗示压缩空间, 但「通用语料低 ID」!=「硬任务低 ID」;
- **剪枝 / 量化**: 除困惑度外, 监控 PR 曲线、关键概念方向余弦漂移、长尾任务;
- **蒸馏**: 若只匹配最终 logits, 中层可控方向与推理轨迹几何可能被破坏--如需保持可控性, 考虑中间层匹配或方向回归项。

方向漂移监测

$$\text{drift}(t) = 1 - \cos(v_c^{(t)}, v_c^{(0)})$$

5.7 与流形基础、表示几何的显式连接

- ID 回答 §02 的「局部需要几张坐标」；
- 谱能量集中对应「平坦近似可用 PCA」；
- 邻域 ID 对分支敏感，呼应 atlas / 流形并；
- §03 的 Purity 高而 ID 低：理想的「薄而可分」；
- Purity 低而 ID 低：可能塌缩到无信息区域（需警惕）。

5.8 常见错误

- 把 UMAP 的 2 维当成 d_{id} ；
- 样本 n 过小却比较两位小数；
- 混合多语言多领域还声称单一 ID；
- 用训练探针的同一批点估计 ID 并过度解读。

自学加餐·ID（数字怎么读）

PR=12 而 $d=4096$ ：人话是「大约一打主通道在冒泡」。接着问：协议？第二种估计是否同向？是否多领域混合？与探针峰是否同层？不要说「智商=12」。

5.9 本章检查清单

- ☐ 同时报告 d 与 $d_{\text{id}}/\text{PR}/r_\tau$
- ☐ 至少两种估计器看趋势
- ☐ 协议（层/位置/模板/度量）固定可复现
- ☐ 分层处理明显多模态点云
- ☐ LoRA 启发后有下游消融

§ 06 推理流形、失败几何与监测

Reasoning Manifolds, Failure Geometry & Monitoring · RapidAi Research

若表示点落在语义流形附近，多步推理就是状态空间中的一条路径。正确解题是否走在可识别的「安全廊道」里？错误是早期分岔、中途滑落还是终点幻觉？本章给出推理流形的工作定义、轨迹特征、对错分离指标、失败分型与可上线的监测/干预接口，并不断扣回 §02 的路径与度量语言。


读前预备：§0C.10（解码随机性）、§0B.7（AUC）、§02.5（路径 vs 弦长）、§04（方向拉回）。

先做：§11 Lab4 的二维玩具，再上真题。

6.0 入门类比：夜航与航道

正确推理像船只留在航道（推理流形）内；灯塔是原型 c ；雷达距离是 $d_*(h_t, c)$ ；偏航告警是 alarm_t 。风浪（高温采样）会把船推向礁石（错误盆地）。终点碰巧到港（答对）但中途搁浅过，属于虚假推理--不能只看结局。

图 06-1 正确航道、错误盆地与分岔



读图：关键不是终点绿点，而是分岔点何时出现。 t^* 越早，越有机会干预。虚假推理 = 终点碰巧对，但中途进过红圈。

形式定义

推理流形与监测

$\tau = (h_t)$; $\mathcal{R}$ 为正确轨迹支撑; $d_*(h, c) = \sqrt{(h - c)^\top G(h - c)}$; alarm 阈值化。

物理直觉

夜航航道 · 灯塔 · 偏航笛

航道=正确廊道; 灯塔=原型 c ; 雷达距离拉大就鸣笛。进红漩涡=错误盆地。终点碰巧靠港但曾搁浅=虚假推理。

轨迹 τ

状态序列，不是最终答案字符串本身。

原型 c

正确轨迹的聚合中心（金标或教师）。

盆地 basin

被某错误吸引子「吸住」的区域。

AUC_t

第 t 步分数区分最终对错的能力。

6.1 工作定义

给定任务族 $\mathcal{T}$ 与模型 f_θ ，考虑生成（或隐层）过程中的状态序列。令所有导向**正确最终答案**（或正确中间证明状态）的轨迹集合为 $\mathcal{R}_{\text{raw}}$ 。称其在状态空间中的低维支撑及薄邻域为 **Reasoning Manifold**（工作定义） $\mathcal{R}$ 。允许不连通：不同题型可以是不同分支。

$$\tau(x) = (h_0, h_1, \dots, h_T), \quad h_t \in \mathbb{R}^d.$$

h_t 的常见取法：

- CoT 第 t 步最后一个 token 的第 ℓ 层激活；
- 仅前向、无显式 CoT 时的层间状态（静默轨迹）；
- 答案槽位 token 的状态（简答题）。

与 §02 的关系： τ 是路径的离散采样； d_* 依赖度量 G ；错误类型往往对应流形并上的其它分支（盆地）。

6.2 轨迹特征：步长、原型距离、盆地

步长与马氏型距离

$$\delta_t = \|h_{t+1} - h_t\|, \quad d_*(h, c) = \sqrt{(h - c)^\top G(h - c)}$$

盆地归属

$$\text{basin}(h) = \arg \min_{k \in \{0, 1, \dots, K\}} d_*(h, e_k)$$

其中 $e_0 := c$ 为正确原型（金标轨迹聚合或教师状态均值）， $e_1, \dots, e_K$ 为错误吸引子（常见失败模式聚类中心）。 $G = I$ 或白化/因果度量。

还可记录：与最终层方向对齐、与「细心计算 / 检索」等概念方向的投影 $p_t(v)$ (§03-§04)、局部 PR 沿轨迹的变化。

6.3 正确 vs 错误：分离性指标

信号	正确轨迹上常见	失败轨迹上常见
$d_*(h_t, c)$	单调或阶梯下降	平台、回升、振荡
δ_t	中期稳定、收尾收敛	暴冲或过早塌缩
自洽/已知探针	稳定	拒答与瞎编方向交织
层间对齐	向答案方向对齐	中层偏离后难拉回

逐步 AUC 与最早可分步

$s_t = -d_*(h_t, c)$ 或线性探针分数， $AUC_t = \text{ROC-AUC}(s_t, y_{\text{final}})$

$t^* = \min\{t : AUC_t \geq \tau\}$ （如 $\tau = 0.8$ ）

金标来源：教师正确 CoT、短答案反向约束解码、人工校对步骤。用多数票自洽样本作为原型时，必须在报告中声明，并单独评估虚假推理。

6.4 失败模式 taxonomy

- 1. **早期分岔**：题意理解错，1-2 步进入错误分支；
- 2. **中途滑落**：前半正确，关键计算/引用错误后落入错误盆地；
- 3. **终点幻觉**：过程看似合理，终点投影到高置信错误答案；
- 4. **循环**：状态在子空间打转， δ_t 不减、文本重复；
- 5. **过短切**：未进入推理廊道，直接跳到高频答案 token。

二维玩具（用于测流水线）

设 $h_t \in \mathbb{R}^2$, $c = (1, 0)$, $e = (0, 1)$ 。正确样本沿 c 做带收缩噪声的随机游走；错误样本在指定步 t_{shock} 被加性冲击推向 e 。完整流水线应得到 $t^* \approx t_{\text{shock}}$ 。若否，先修特征与标签对齐，再解释真实模型。

6.5 监测、早停与拉回

$$\text{alarm}_t = \mathbf{1}[d_*(h_t, c) > \eta_t \vee \text{basin}(h_t) \neq 0]$$

- **早停重采样**：触发 alarm 则回溯 beam / 提温重采；
- **方向拉回**： $h \leftarrow h + \alpha \hat{v}_{\text{careful}}$ 或指向题型原型；
- **工具切换**：几何上进入「需外计算」区域时调用计算器/检索；
- **阈值校准**：在验证集上用目标 FPR 选 η_t （可随 t 变化）。

一阶近似再次出现：拉回步长 α 过大可能直接离流形 (§02.10)。必须扫剂量并监控流畅度。

6.6 与过程奖励、搜索解码的接口

过程奖励模型 (PRM) 学习「是否仍在正确廊道」。几何视角提供可解释特征：

$$\phi_t = (d_*(h_t, c), \delta_t, \text{basin one-hot}, p_t(v_1), \dots)$$

可与标量 $\Phi(h_t)$ 融合，或作为 MCTS / beam scoring 的辅助项。注意：终点正确 != 中间在 $\mathcal{R}$ 上（虚假推理），故仅结局奖励不够时，更需要逐步几何或逐步人工标注。

6.7 采样、温度与「经验覆盖」

温度、top-p、nucleus 改变的是轨迹分布的覆盖，而不是单次前向的定义。评测推理流形时：

- 固定解码协议；
- 每题 K 条 sample（如 $K = 5 \sim 20$ ）；
- 同时报 pass@K 与几何可分性，避免只见结局不见路径。

6.8 局限

- 多正确路径 => 单原型不够，需多原型或密度模型；
- 开链生成噪声大，需聚合；
- 无逐步标注时，伪标签会美化虚假推理；
- 跨模型迁移推理流形仍是开放问题 (§09)。

自学加餐·推理（批改作文）

老师不只看最终分，还看第几段跑题。原型 c =范文中心； $d^*(h_t, c)$ =离范文距离； t^* =最早能预判写砸的段号；拉回=重写该段而非整篇碰运气。

6.9 本章检查清单

- [] 状态取自哪一层 / 哪个 token 写清
- [] 金标或伪原型来源声明
- [] 报告 AUC_t 与 t^* , 不只看图
- [] 失败案例按 taxonomy 归档
- [] 干预有 dose-response 与随机对照

§ 07 端到端实验流水线（实验室手册）

End-to-End Experimental Pipeline · RapidAi Research

前文章节给出对象与指标；本章把它们串成一条可重复流水线。目标不是「一次跑出神奇图」，而是让任何同事按配置能复现你的曲线与结论，并明确区分相关与因果。

读前预备： §03-§06 的指标含义； §0B 的数据划分与基线。

输出物： config.yaml + REPORT.md + directions/ + 曲线 CSV。

7.0 新手最短路径（两天版）

1. Day1 上午：冻结协议，采一层激活做探针（相关）；
2. Day1 下午：diff-in-means + 随机对照；
3. Day2 上午： α 网格与层扫 PR；
4. Day2 下午：写一页决策与失败案例。

两天后若指标不稳，回头检查协议与样本量，而不是先上 SAE。

图 07-1 流水线不要跳步：相关 -> 因果 -> 决策



Archive 全程伴随：config · 种子 · 方向哈希 · 失败案例。跳过 Intervene 直接 Decide = 不合格。

读图： Describe/Probe 只能支持「看得见」；没有 Intervene 对照，就没有「推得动」的工程权限。

7.1 八阶段总览

- | | |
|--------------|-------------------------|
| 1. Scope | 任务 / 模型 / 层 / 位置 / 成功标准 |
| 2. Collect | 激活 + 元数据（标签、对错、步骤） |
| 3. Describe | PR/ID、谱、邻域、可视化（附） |
| 4. Probe | 线性读出与基线 |
| 5. Intervene | steering / 消融 / 随机对照 |

- 6. Reason-geo 轨迹分离与失败分型（多步任务）
- 7. Decide 层、rank、阈值、风险
- 8. Archive 版本、种子、配置、图表、方向文件

成功标准示例

$$\text{Acc}_{\text{probe}}^{\text{test}} \geq \text{Acc}_{\text{base}} + 0.10$$

$$\exists I : \forall \alpha \in I, \Delta(\alpha) \geq \Delta_{\text{rand}}(\alpha) + \delta, \quad \text{degrade}(\alpha) \leq \epsilon$$

7.2 阶段 1：范围冻结

项	示例
模型	Llama-3-8B-Instruct, bf16
任务	毒性二分类 / GSM8K 子集 / 拒答
钩子	每层 residual post-MLP
位置	最后输入 token; CoT 用每步末 token
模板	system+user 版本号 v3
种子	0,1,2 三重复

中途改协议 = 新实验。用 git 提交 config，而不是靠记忆。

7.3 阶段 2：数据采集

- 正负 / 对错分层抽样；记录来源与许可证；
- 激活：memmap / zarr；元数据：parquet；
- 存 tokenizer 版本、生成参数、精度、hook 点；
- 用户数据先脱敏。

目录约定

```
runs/2026-08-13_gsm8k_l3-8b/  
  config.yaml  
  activations/layer_XX.npy  
  meta.parquet  
  metrics/probe.json
```

```
metrics/steer_curves.csv
metrics/id_curves.csv
figures/
directions/v_c.pt
REPORT.md
```

7.4 阶段 3：描述统计（接 §02B-§05）

1. 每层 PR、 $r_{0.95}$ ；关键层补 TwoNN；
2. Purity@k、类内类间比；
3. UMAP 附图（可选）；
4. 异常值与近重复检查。

7.5 阶段 4：探针

- train/val/test 严格分离；
- 随机标签基线；
- 切片：长度、语言、题型、模板；
- 得到 $\ell_p = \arg \max_{\ell} \text{Acc}(\ell)$ 。

7.6 阶段 5：干预（因果）

```
for alpha in grid:
    h' = h + alpha * v_hat
    measure J(h'), degrade(h')
compare v_hat vs random vs shuffle_labels
optional ablation: h' = h - proj_v(h)
```

$$\ell_s = \arg \max_{\ell} \max_{\alpha \in \mathcal{A}} \Delta_{\ell}(\alpha)$$

注意 ℓ_p 与 ℓ_s 可以不同：可读 != 可控。

7.7 阶段 6：推理轨迹包（若任务多步）

- 每题 K 条 sample；
- 原型与错误吸引子；
- AUC_t 、 t^* 、taxonomy 标注；
- 虚假推理抽样人工读。

7.8 阶段 7：决策出口

一页纸必须包含

- 监测层与阈值 η ;
- 方向文件哈希、适用域、失效样例;
- LoRA rank 搜索区间;
- 已知串扰与误用;
- config commit / 种子。

7.9 阶段 8：归档与回归

每次换底座或系统提示，重跑「最小回归几何套件」：PR 曲线 + 主任务探针 + 主方向 $\Delta(\alpha)$ 三点。把结果写入趋势表，而不是只留截图。

7.10 时间盒

- MVP 扫描：1-2 天;
- 含因果 steering：3-5 天;
- 含推理轨迹：1-2 周兼职。

自学加餐·流水线（一人实验室）

周末两天版：

1. 半天写死协议 + 采激活;
2. 半天探针与随机标签;
3. 半天 diff-in-means + alpha 网格 + 随机方向;
4. 半天写一页纸：层、阈值、失效样例、仍不知道什么。

没有第 4 步，前三步只是 excels 堆积。

7.11 检查清单

- [] 范围表冻结
- [] 数据可复现加载
- [] 相关 vs 因果分离

- [] 对照方向齐全
- [] REPORT.md 可独立阅读

§ 08 应用：可解释、对齐、RAG、PEFT

Applications · RapidAi Research

几何分析的出口是决策。本章把流形 / 方向 / ID / 轨迹接到四类高频工作。每节按「场景故事 -> 你要什么 -> 怎么做 -> 公式接口 -> 新手坑」组织，尽量让第一次做的人也能照着走。

读前预备：§0 五样图像、§04 因果验证、§05 有效秩、§06 监测、§07 一页纸。

读法：只精读与你工作相关的一节；其余当字典。

8.0 应用选择树（入门）

- 想解释模型内部 -> §8.1;
- 想做安全/拒答控制 -> §8.2;
- 想查「检索有没有被用上」 -> §8.3;
- 想选 LoRA rank / 插层 -> §8.4;
- 想上线监测 -> §8.5。

图 08-1 应用不是另起炉灶：都是同一套对象-指标-干预



读图：五块业务不同，底层仍是便签、方向、曲线、对照。

8.1 机械可解释性

场景故事

产品经理问：「模型为什么突然开始用这种口吻？」你需要的不是玄学，而是一张**特征卡**：什么输入激发它、推动它会怎样、在哪一层最清楚。

- **目标：**特征、回路、因果路径；

- **动作**：概念方向、SAE 原子、层轨迹、消融；
- **交付**：特征卡（激发/抑制例子 + $\Delta(\alpha)$ + 层）。

$$\text{Effect}(\alpha) = \mathbb{E}[J(h + \alpha \hat{v}) - J(h)], \quad \text{Selectivity} = \frac{\text{Effect}_{\text{on}}}{\text{Effect}_{\text{off}} + \varepsilon}$$

检查：激发集 / 抑制集 / 随机对照 / 跨提示泛化 / 到 logits 链路。禁止单张 UMAP 充当机制证明。

新手先做

diff-in-means + 探针 + 10 条人工读例子。

新手别先做

全库 SAE、跨模型回路拼接。

8.2 对齐与安全

场景故事

用户用婉转说法绕过拒答。硬规则关键词拦不住。你希望有一个「谨慎/拒答」旋钮：小幅监测，而不是只会 0/1 切断。

$$h' = h + \alpha_r \hat{v}_{\text{refuse}} + \alpha_h \hat{v}_{\text{honest}}$$

- 小 α 监测优于只靠硬拒；
- 看中层是否已入有害盆地（§06）；
- 用串扰矩阵管理多目标（安全升、有用掉？）；
- 上线前红队 + OOD；方向与提示模板绑定版本。

形式

串扰

干预方向 A 时，非目标指标 B 的 $\Delta_B(\alpha)$ 。

人话

拧甜味却变咸

旋钮不独立。表格式记录「拧 A 时 B 变多少」，比口头说「有点影响」有用。

安全实验遵守法规与平台政策；本手册不提供攻击配方，只谈防御向测量。

8.3 RAG 与知识边界

场景故事

系统提示里贴了检索文档，但模型仍背训练记忆里的旧价格。你要判断：检索有没有被「用进」内部状态？

$$g_t = \cos(h_t, v_{\text{evidence}}) - \cos(h_t, v_{\text{parametric}})$$

1. 比较仅参数 vs 带检索的轨迹区域；
2. 检测「检索未融入」（证据在提示里，状态仍走老路）；
3. 冲突题上看是否振荡；
4. g_t 作门控前必须在验证集校准阈值。

开卷

RAG = 允许翻书。

几何问题

翻了书，草稿有没有转向书页？

8.4 PEFT / LoRA / 续训

场景故事

要为客服话术微调 7B 模型。全量太贵。LoRA rank 选 8 还是 64？插哪些层？

问题	几何启发	行动
rank	任务差分有效秩 $\hat{r}$	$r \in \{\hat{r}/2, \hat{r}, 2\hat{r}\}$
插哪层	ℓ_p, ℓ_s	优先敏感层
遗忘	旧任务邻域	回放 + 原型正则
伪相关	与混杂对齐	切片与消融

$$\mathcal{L} = \mathcal{L}_{\text{task}} + \beta \mathbb{E}[\|h - c_{\text{old}}\|^2 \cdot \mathbf{1}_{\text{old}}]$$

新手坑：rank 启发只是数量级。必须跑下游指标；不同模块（attn vs mlp）有效秩可不同。

8.5 评测与线上监控

$$\text{drift} = 1 - \cos(v_c^{(t)}, v_c^{(0)})$$

- 离线双仪表盘：任务指标 + 几何指标；
- 在线轻量投影（延迟/隐私约束）；

- 漂移超阈 -> 重估方向；方向文件与模型版本绑定。

形式 方向漂移 $1 - \cos(v^{(t)}, v^{(0)})$.	人话 旋钮是否还指着同一格 换底座、换系统提示后，旧旋钮可能拧到空气。 要定期校准。
---	---

8.6 沟通话术（给非技术同事）

- 说「地图与路径 / 旋钮」，不说玄学时空；
- 出示 $\Delta(\alpha)$ 曲线，一图胜千言；
- 强调：换模型必重测，没有一劳永逸方向。

8.7 优先级路线

1. 探针 + diff-in-means + 随机对照；
2. PR/ID 层扫 + 干预网格；
3. SAE / 全链路 / 线上门控。

8.8 总检查清单

- [] 危害模型清晰（尤其安全向）
- [] 隐私与协议写清
- [] 相关 vs 因果分离
- [] 对照任务与随机方向
- [] 失败案例库
- [] 版本归档（模型/模板/方向哈希）

§ 09 进阶主题、理论边界与展望

Advanced Topics, Limits & Outlook · RapidAi Research

入门工具箱之后，是更强也更易误用的方法：SAE、表示工程、跨模型映射与理论边界。原则不变--隐喻服务实验，证据优先于文采。

读前预备：已完成至少一次 §07 流水线；理解叠加 (§04.6)。

警告：本章方法成本高，入门阶段不要跳过基线直接上全库 SAE。

9.1 稀疏自编码器 (SAE)

$$f = \sigma(W_{\text{enc}}(h - b_{\text{pre}}) + b_{\text{enc}}), \quad \hat{h} = W_{\text{dec}}f + b_{\text{dec}}$$

$$\mathcal{L} = \|h - \hat{h}\|_2^2 + \lambda \|f\|_1$$

- 字典列 $\sim$ 候选轴 / 局部坐标 (接 §02B)；
- 活跃集合变化 $\sim$ 图表切换；
- 无 steering / 消融验证的「自动可解释」不可信。

建议顺序：探针与 diff-in-means 基线 -> 再上 SAE。否则无法判断字典是否改进因果控制。

9.2 表示工程与离流形风险

$$h_{\text{new}} = \Pi_{\mathcal{M}}(h + \Delta) \quad \text{或约束} \quad d_*(h + \Delta, \mathcal{M}) \leq \varepsilon$$

过大编辑导致乱码、人格崩坏或空转高置信，是典型的「一阶欧氏步离开数据支撑」 (§02.10)。

9.3 跨模型映射

$$h^{(B)} \approx Th^{(A)}$$

移植方向或合并 LoRA 前，检查 $Tv_c^{(A)}$ 在 B 上是否仍有 $\Delta^{(B)}(\alpha)$ 。阴性结果有价值，应写入回归套件。

9.4 理论边界

- NTK / 平均场等很少直接给出可即用层号；
- 表达能力定理 != 已学习某流形的证成；
- 高维小样本 ID 偏差大，趋势重于绝对值；
- 不可证伪的宏大公式不要写进报告。

需要避免的伪公式

$$\text{Intelligence} \neq \kappa \cdot d_{\text{id}}$$

9.5 叙事滥用清单

1. 科幻语气替代实验；
2. UMAP 颜色当因果；
3. 单种子推广为普遍规律；
4. 忽略模板与解码协议；
5. 把工作定义写成定理。

9.6 开放问题

- 推理流形跨模型迁移；
- 在线自适应因果内积的稳定性；
- PRM 是否等价于到 $\mathcal{R}$ 的势函数；
- 多模态共享语义流形的最小充分统计；
- 低开销生产级几何监测。

可开题最小实验

三指令模型 + 同一 GSM8K 子集；各估正确原型 $c^{(m)}$ ；学 $T_{m \rightarrow m'}$ ；报迁移后 AUC_t 与 steering 是否仍显著。

9.7 相邻领域接口

领域	接口
持续学习 / Agent	新技能新分支且不毁旧流形

领域	接口
安全对齐	有害盆地边界与可逆干预
压缩部署	保任务 ID 与关键方向
评测科学	几何漂移作污染/泄漏指示

9.8 读完之后

- 1. 用真实任务跑完 §07;
- 2. 沉淀方向与层手册;
- 3. 换底座重跑最小回归套件;
- 4. 按附录 B 精读论文，而非一次吞百科。

结语 (RapidAi Research)：流形语言的价值，是逼我们写出可测对象、可对照实验与可回滚干预。当隐喻帮助设计实验时保留它；当隐喻开始替代证据时，删掉它。

§ 10 常见问题、误区与排错

FAQ, Pitfalls & Troubleshooting · RapidAi Research

本章按「问题 -> 短答 -> 展开 -> 指向章节」组织，适合组会速查与排错。先读加粗短答，再决定是否深入。

入门者怎么用：每学完一章，到这里搜相关关键词；做 Lab 卡住时先查 §10.3 排错表。完全不懂术语时先回 §0、§0D；要算例回 §0E；要理论边界回 §0F。

10.0 预备知识与新手快问

Q0-new. 我完全没学过线代，能读吗？

短答：能。先读 §0 新手地图与 §0D；§0A 只看例题和双栏。等 Lab 需要时再回看公式。

Q0-story. 流形是不是就是弯弯曲曲的曲面？

短答：不必须弯。平坦桌面也是流形。关键是局部像平地。见 §02。

Q0-white. PDF 里白方块是什么？

短答：旧版缺字形。请打开 v2.3.1+；清单为 []。

Q0. 线代很久没碰，要补到什么程度？

短答：会投影、余弦、PCA 直觉即可 (§0A)，不必先修完谱图理论。

Q0b. 概率只记得均值方差够吗？

短答：再加 held-out、随机基线、AUC 直觉 (§0B) 就够跑通入门实验。

Q0c. 没训练过 Transformer 能读吗？

短答：能。先读 §0C，会「前向取 $h_{\ell,t}$ 」即可开始 Lab1。

10.1 概念类

Q1. 流形是不是就是降维？

短答：不是。降维是工具；流形是关于数据支撑的几何假说与工作对象。详见 §02。

Q2. 流形一定要弯曲吗？

短答：不必。线性子空间是平坦流形。LRH 常在平坦近似下工作。

Q3. 内在维度低是不是模型更强？

短答：不能这样推。低 ID 可能是压缩，也可能是塌缩。要看可分性与下游任务 (§05)。

Q4. 余弦相似度能代表语义吗？

短答：取决于度量与协议。先声明 G 与层/位置；必要时白化或因果内积 (§02.6、§04.5)。

10.2 实验类

Q5. 探针很高，但 steering 没效果？

短答：相关!=因果。可读出不等于可控制。试不同层 ℓ_s 、子空间干预、检查叠加与混杂 (§04、§07)。

Q6. 为什么换个提示模板曲线全变？

短答：模板是坐标变换的一部分。协议未冻结则实验不可比 (§02.8、§07.2)。

Q7. UMAP 分簇很漂亮，可以写进结论吗？

短答：只能当附图。结论靠 Purity、AUC、 $\Delta(\alpha)$ 等 (§02B.7)。

Q8. ID 估计每次跑数字都不一样？

短答：正常。看趋势与置信区间；增大 n 、去重、固定 k 与种子；多估计器交叉 (§05)。

10.3 实现排错

症状	可能原因	处理
公式显示源码	未加载 KaTeX / PDF 未等待	见附录 A；检查 assets/katex
层曲线锯齿剧烈	样本过少、近重复、位置乱	增 n 、去重、固定 t^*
steering 一推就乱码	α 过大、方向沾噪声	缩小网格、归一化、对照随机方向
跨层方向不迁移	几何旋转/重写	分层估方向；学层间映射
RAG 门控乱触发	未校准 g_t	验证集调阈；分层领域
多卡数值不一致	精度/归约顺序	固定 dtype 与种子；记录内核版本

10.4 表述与评审

- 把「工作定义」写成「定理」会被追问证明--自己先降级措辞；
- 单模型结果写成「LLM 普遍」会不通过--改成案例；
- 缺少随机对照的因果声明应撤回；
- 方向文件无适用域与失效样例 = 不可交付。

组会 5 分钟汇报结构

1. 协议一句话;
2. 一张层曲线;
3. 一条 $\Delta(\alpha)$ (含随机对照) ;
4. 一个失败案例;
5. 一个工程决策 (层/rank/阈值) 。

10.5 与基础章相关的典型误区

- 把弦长当测地距 (§02.5) ;
- 在多分支数据上跑单一 Isomap 叙事 (§02B.3) ;
- 大 α 仍用切空间一阶故事 (§02.10) ;
- 混淆 ambient 维与 ID (§05.1) 。

10.6 检查清单

- [] 能用一句话区分相关/因果
- [] 能指出本项目最大协议风险
- [] 有随机对照与失效样例
- [] 结论措辞与证据级别匹配

§ 11 导修练习与迷你实验

Tutorials & Mini-Labs · RapidAI Research

纸上谈几何不够。本章给出可在小模型或子集上完成的导修实验。每个 Lab：目标、材料、步骤、交付、评分点。可作课程作业或入职训练。

入门顺序：§0 口述自测通过 -> §0E 至少完成投影手算 -> §0D 翻译练习 -> §0A-§0C 笔头练习 -> Lab1 -> Lab2 -> Lab3；有余力再 Lab4-5。

时间盒：每个 Lab 3-8 小时；超时先降数据量，不降对照。

Lab0 · 零 GPU 热身 (30 分钟，必做)

1. 用自己的话讲「工厂便签」故事 (§0)；
2. 默写协议四元组；
3. 完成 §0D.6 四句黑话翻译；
4. 解释：探针高为什么还不能上线 steering。

过关后再碰模型。否则容易会跑脚本、不会解释结果。

11.0 通用准备

- 模型：任意 1-8B 级指令/基座模型（资源紧可用更小蒸馏模型）；
- 硬件：单卡 GPU 更佳；CPU 可做玩具随机投影版；
- 工具：NumPy / PyTorch、线性探针（逻辑回归）、可选 UMAP；
- 纪律：先写 config，再跑代码；种子固定。

11.0b 预备练习 (不占 GPU, 30-60 分钟)

1. §0A 练习 1-3（投影与范数）；
2. §0B 练习 2、5（不平衡 Acc 与 AUC）；
3. §0C 练习 1、3（框图与模板协议）；
4. 默写 hook 四元组：模型 / 层 / 位置 / hook 点。

全部完成后，再开始 Lab1。若预备练习卡关，不要用「先跑代码再说」跳过--后面只会在概念上反复摔跤。

11.1 Lab 1 · 点云协议与邻域 (对接 §02-§03)

目标：冻结协议并测量语义邻域。

1. 构造近义改写 300 对 + 干扰 300 条；
2. 取 3 个层的最后 token 激活；
3. 计算 Purity@10、类内/类间比；
4. 附图 UMAP (可选) 。

交付：曲线图 + 半页解读。

评分点：协议是否写清；是否误用 UMAP 当结论。

$$\text{Purity}@k(\ell), \quad R(\ell)$$

11.2 Lab 2 · Diff-in-means 与因果对照 (§04)

目标：区分相关与因果。

1. 二分类任务 (情感/毒性) 各 ≥ 1000 训练 / 500 测试；
2. diff-in-means + 探针 Acc；
3. 随机标签探针；
4. α 网格 steering；随机方向对照；
5. 记录流畅度/崩坏边界。

交付： $\Delta(\alpha)$ 曲线 CSV + 图。

评分点：有无随机对照；是否把崩坏当成功。

11.3 Lab 3 · PR / ID 层扫 (§05)

目标：报告有效维趋势。

1. 每层采样 $\geq 2e4$ token 激活 (可子采样通道做预实验) ；
2. PR 与 $r_{0.95}$ ；
3. 峰值层补 TwoNN 或 MLE；
4. 与 Lab2 探针曲线同图叠加。

交付：日志模板填空 (§05.4) 。

评分点：是否同时报 d ；是否只报单点绝对值。

11.4 Lab 4 · 推理轨迹玩具 + 真题 (§06)

目标：打通 t^* 流水线。

1. 先跑二维玩具，验证 $t^* \approx t_{\text{shock}}$ ；
2. 再在 50 道短推理题上采 $K = 5$ 条；
3. 构建正确原型与 1 个错误吸引子；
4. 报 AUC_t 与失败 taxonomy 计数。

交付：AUC 曲线 + 10 条人工读过的轨迹笔记。

11.5 Lab 5 · 一页纸工程决策 (§07-§08)

目标：把分析变成决策。

- 写出监测层、 η 、方向哈希、适用域、失效样例；
- 给出 LoRA rank 搜索区间（若有微调场景）；
- 列出 3 条误用警告。

交付：一页 PAPER_DECISION.md。

11.6 进阶选修

- 白化度量下重做 Lab2，比较串扰；
- 小规模 SAE 字典 50 原子，做激发样例卡；
- 两模型方向迁移 (§09.3)。

课程排期建议 (4 周兼职)

W1: Lab1 + 读 §02/02B; W2: Lab2 + §04; W3: Lab3 + §05; W4: Lab4-5 + §06-08。每周组会用 §10.4 的 5 分钟结构。

11.7 学术诚信与安全

- 不要为了「好看」剔除失败种子而不报告；
- 安全方向实验遵守法规与平台政策；
- 公开数据注意许可证；用户数据脱敏。

11.8 检查清单

- ☐ 每个 Lab 有 config
- ☐ 交付物可复现
- ☐ 对照齐全
- ☐ 失败也记录

§ A 附录 A • 术语、公式与构建

Appendix A · Glossary, Formulae & Build · RapidAi Research

图怎么读
正文 figure 均含「读图」一句；先看图再看公式。

概念卡片
紫/蓝小卡片是「人话定义」，可当闪卡背。

协议
模型·层·位置·hook 四元组，比任何炫图优先。

对照
随机方向 / 随机标签 / held-out，三角缺一不可。

A.1 术语表 (含预备概念)

术语	工作定义	首见
向量 / 内积 / 投影	$\langle u, v \rangle, \text{proj}_v h$	\$0A
PCA / SVD / 秩	谱分解与低秩近似	\$0A
期望 / 方差 / AUC	统计估计与排序指标	\$0B
残差流 / hook	Transformer 主状态与探针挂载点	\$0C
Ambient dim d	hidden size	\$02
Chart / Atlas / $T_p M$	局部坐标与切空间	\$02
$d_{\text{id}}, \text{PR}, r_\tau$	有效维估计	\$05
LRH / Steering	概念方向与加性干预	\$04
Reasoning manifold	正确轨迹支撑 (工作定义)	\$06
SAE	稀疏自编码器字典	\$09

A.2 公式速查

$$\text{proj}_v h = \frac{\langle h, v \rangle}{\langle v, v \rangle} v, \quad h' = h + \alpha \hat{v}$$

$$x_{\ell+1} = x_{\ell} + \text{Attn}_{\ell} + \text{MLP}_{\ell}$$

$$\text{PR} = \frac{(\sum \lambda_i)^2}{\sum \lambda_i^2}, \quad d_{\text{id}} \approx \frac{n}{\sum_i \log(r_2^{(i)} / r_1^{(i)})}$$

$$d_*(h,c) = \sqrt{(h-c)^\top G(h-c)}, \quad \text{AUC}_t = \text{ROC-AUC}(s_t, y)$$

A.3 构建

```
node build.js
node build-pdf.js
# 公式 \langle ... \rangle 与 \lceil ... \rceil; 本地 KaTeX
# 作者: RapidAi Research
```

A.4 交付检查

- 预备篇三章在目录最前
- 封面版本 v2.1.x, 作者 RapidAi Research
- PDF 公式已渲染, 中文正常

§ B 附录 B • 阅读路线与主题索引

Appendix B · Reading Tracks & Topic Index · RapidAi Research

B.1 角色路径（含预备篇）

角色	建议阅读	必做
完全新手	§0, §0E, §0F, §0D, §0A 双栏, §01	Lab0 + Lab1
补数学	§0A-§0C 全文	预备练习
研究生入门	§0A 快刷, §01-§05, §10	Lab1-3
Mech-interp	§0C, §03-§06, §09.1	Lab2,4
应用工程师	§0C, §03, §05, §07-§08	Lab3,5
对齐 / 安全	§04, §06, §08.2, §10	Lab2,4
训练 / PEFT	§05, §07, §08.4	Lab3,5

B.2 主题索引

- 向量 / 投影 / PCA -> §0A, §05
- AUC / 高维近邻 -> §0B
- 残差流 / hook / 解码 -> §0C, §03
- 坐标图 / 切空间 / 度量 -> §02
- Isomap / LLE / UMAP 用法 -> §02B
- LRH / steering / 因果内积 -> §04
- PR / TwoNN / LoRA rank -> §05
- 推理轨迹 / alarm -> §06
- 实验流水线 -> §07
- RAG / 串扰 / 监控 -> §08
- SAE / 跨模型 -> §09
- 排错 -> §10
- 作业 Lab -> §11

B.3 依赖关系（不要逆着读）

$0A/0B/0C \rightarrow 01 \rightarrow 02 \rightarrow 02B \rightarrow 03 \rightarrow 04 \rightarrow 05$

$04/05/06 \rightarrow 07 \rightarrow 08$, 11 穿插, 09 最后

B.4 文献主题锚点

- 线代与 PCA 教材章节；高维概率导论
- Attention is All You Need；decoder-only LM 综述
- Manifold hypothesis；Isomap；LLE；TwoNN
- Linear representation；steering；superposition；SAE
- Process reward；self-consistency

B.5 符号速记

$h_{\ell,t}, d, k, d_{\text{id}}, v_c, \alpha, G, \text{PR}, r_\tau, \tau(x), d_*, t^*$

B.6 给讲师 / 组长

1. 第 1 周只允许讲预备篇 + §01-§02，禁止直接上 SAE；
2. 每个 Lab 强制随机对照项，否则不给分；
3. 组会采用 §10.4 的 5 分钟结构；
4. 换模型世代时，更新 Lab 参考数字而非空谈。

§ C 附录 C · 概念双栏：形式定义 x 物理直觉

Appendix C · Formal Definition x Physical Intuition · RapidAi Research

本附录把全书核心概念做成统一版式：**左栏形式定义**（可写进笔记/论文的工作表述），**右栏物理/操作直觉**（用可感知的图像与实验动作理解）。两栏必须一起读：只有公式会背不会用；只有比喻会飘。正文各章首次出现时也会插入同款双栏。

怎么用：① 学新概念先看右栏建立感觉；② 做实验前用左栏核对符号；③ 写报告时左栏可作定义段，右栏可作「直观说明」段。

C.1 预备：线性代数与测量

形式定义

向量 $h \in \mathbb{R}^d$

有序实数组，可加可数乘。激活矩阵一行/一列对应一个状态向量。

物理直觉

一根带方向的箭头 / 一张便签上的 d 个读数

在 LLM 里：某个 token 在某层的「内部状态快照」。你要先问：这张便签是谁的、在哪一层拍的。

形式定义

内积与余弦

$\langle u, v \rangle = u^\top v$ (或 $u^\top Gv$)。 $\cos \theta = \langle u, v \rangle / (\|u\| \|v\|)$ 。

物理直觉

两箭夹角：朝向是否差不多

像比较两支指南针是否指同一方位。长度先归一，只关心「往哪边」。换尺子 G 等于换了一种量角度的方法。

形式定义

投影 $\text{proj}_v h$

$\text{proj}_v h = \frac{\langle h, v \rangle}{\langle v, v \rangle} v$ 。正交分解 $h = \text{proj}_v h + h_\perp$ 。

物理直觉

影子落在轴上有多长

太阳从垂直于 v 的方向照过来， h 在 v 轴上的影子。影子长 = 概念强；砍掉影子 = 消融；顺着轴再挪一步 = steering。

形式定义

PCA / 有效秩

协方差特征分解; r_τ 为累计方差达 τ 的最小主成分数; $PR = (\sum \lambda_i)^2 / \sum \lambda_i^2$ 。

物理直觉

点云最扁的那几根主轴

像给一堆鹅卵石找「最长、次长」的伸展方向。若几乎成一条线, 有效维 ~ 1 ; 若像实心土豆, 有效维高。PR 小 = 能量集中在少数通道。

C.2 预备: 概率与协议

形式定义

期望与样本均值

$\mathbb{E}[X]$; 样本 $\bar{x} = \frac{1}{n} \sum x_i$ 是其估计。

物理直觉

很多次测量的「平均落点」

称同一物体 100 次取平均。方向 v_c 的 diff-in-means 就是「正类平均位置」减「负类平均位置」。

形式定义

AUC

ROC 曲线下面积; 分数对二分类标签的排序能力, 阈值无关。

物理直觉

随意抽一对正负样本, 分数把它们排对的概率

像裁判给选手打分: 不先定及格线, 只问「好的是不是普遍分更高」。0.5=瞎猜。

形式定义

实验协议

固定 $(\text{model}, \ell, t^*, \text{hook}, \text{template}, \text{dtype})$ 后定义点云 $\mathcal{D}$ 。

物理直觉

实验室仪器档位与取样口

同一锅汤, 从锅边或锅心舀、用大勺或小勺, 化验结果不同。换层/换模板却比曲线, 等于换了取样口还硬比。

C.3 Transformer 对象

形式定义

残差流 residual stream

各层共享改写的主通道: $x_{\ell+1} = x_\ell + \Delta_{\text{attn}} + \Delta_{\text{mlp}}$ (具体 LN 位置依实现)。

物理直觉

传送带上的状态包裹

每个 token 有一个包裹在传送带上往前传; 注意力允许偷看别人包裹; MLP 在自己包裹里塞纸条。几何分析=在约定关卡打开包裹称重。

形式定义

Hook 点

计算图上读取张量的位置，如
`blocks.l.hook\_resid\_post`。

物理直觉

管线上的测压孔

同一根油管，孔开在泵前还是泵后，读数完全不同。写论文不写 hook，等于不写测压孔位置。

形式定义

Logits / softmax

$\text{logits} = W_U h + b$, $p = \text{softmax}(\text{logits})$ 。

物理直觉

词表赛道上的原始分与归一化占有率

logits 像各选手的原始得分；softmax 把得分变成「获奖概率份额」。分析中间几何时，未必每次都要看到最终颁奖。

C.4 流形与表示

形式定义

拓扑流形（工作级）

空间 M 每点有邻域同胚于 $\mathbb{R}^k$ 的开集； $k = \dim M$ 。

物理直觉

局部像平地的薄板 / 路面

地球表面、高速公路路面：站在一小块上觉得是平的，整体可以弯、可以有多条岔路。合法语义 $\sim$ = 薄板；乱码 $\sim$ = 掉到板外泥土里。

形式定义

切空间 $T_p M$

点 p 处全体切向量构成的 k 维线性空间；曲线速度 $\dot{\gamma}(0) \in T_p M$ 。

物理直觉

贴在曲面上的小木板（一阶近似）

在山坡某点铺一小块木板，只在附近像平地。线性探针/小 α steering 默认你还在木板上滑； α 太大就冲出木板。

形式定义

Ambient vs 内在维

Ambient $d = \dim \mathbb{R}^d$ ；内在维 k 或估计量 $d_{\text{id}}, r_\tau, \text{PR}$ 。

物理直觉

房间很大，人只在地毯上活动

d 是房间尺寸； k 是地毯的有效自由度。不能把「房间有 4096 平」说成「人有 4096 种活法」。

形式定义

测地距离 vs 弦长

$\text{dist}_M(p, q) = \inf \text{Len}(\gamma)$ ；弦长 $\|p - q\|$ 为嵌入空间直线距离。

物理直觉

开车里程 vs 直升机直线

两城直线 100 公里，开车盘山可能 300 公里。激活余弦高只说明直升机近，不保证存在合法短改写路径。

形式定义

语义流形 $\mathcal{S}_c$ (工作定义)

固定协议下, 表达概念 c 的激活集合的闭包/薄邻域。

物理直觉

所有「在说同一件事」的状态云

像地图上「咖啡馆」兴趣点聚成的区域: 可以有多片(连锁品牌), 边界模糊, 但应与「加油站」区域可分。

C.5 线性表示与干预

形式定义

LRH (工作表述)

存在 v_c 使 $s_c(h) = \langle h, v_c \rangle$ 与概念单调相关, 且 $h + \alpha \hat{v}_c$ 因果改变相关行为。

物理直觉

调味旋钮

锅里有「咸度」旋钮: 看指针=读出; 拧旋钮=steering; 拆掉旋钮机构=消融。旋钮和「辣度」咬合在一起=叠加串扰。

形式定义

Diff-in-means

$$v_c = \mathbb{E}[h \mid c+] - \mathbb{E}[h \mid c-].$$

物理直觉

两团点云中心的连线

笑脸照片堆的中心, 减去哭脸堆的中心, 箭头指向「更笑」。混进照明差异, 箭头会脏--所以要控制混杂。

形式定义

Steering / 消融

$$h' = h + \alpha \hat{v}; \quad h_{\text{ablate}} = h - \text{proj}_v h.$$

物理直觉

推一把 / 抽掉一根成分

推一把要看剂量: 轻推调味, 猛推掀锅。消融像从果汁里滤掉某种味道, 看还像不像原味。

形式定义

因果内积

$\langle u, v \rangle_* = u^\top G v$, $G \succ 0$, 使概念可加/干预更一致。

物理直觉

换一把更贴业务的尺子

用市尺量布和用软皮尺量腰围, 数值体系不同。白化/因果内积=先按数据伸展把空间拉圆, 再谈垂直与加减。

形式定义

叠加 Superposition

$$h \approx Df + \eta, \quad f \text{ 稀疏, 特征数 } m \gg d.$$

物理直觉

过多电台挤占有限频段

频道不够, 多个节目叠在邻近频率: 听一个会串音。强 steering 误伤邻居概念, 常因叠加。

C.6 内在维度

形式定义

参与比 PR

$$PR = (\sum_i \lambda_i)^2 / (\sum_i \lambda_i^2).$$

物理直觉

能量是否「摊大饼」

若只有一两根柱子撑起总方差，PR 小，像瘦高的天际线；若很多柱子差不多高，PR 大，像平顶城市。

形式定义

TwoNN d_{id}

由最近邻与次近邻距离比 $\mu = r_2/r_1$ 聚合估计局部维。

物理直觉

看邻居圈扩大得多快

在线上，第二近邻往往明显更远的方式不同于在面上。邻居「一圈圈长多快」泄露了当地是几维的布。

C.7 推理轨迹

形式定义

推理流形 $\mathcal{R}$ (工作定义)

正确轨迹集合在状态空间中的低维支撑及薄邻域（可多支）。

物理直觉

夜航航道

船应留在航道内抵达港口。航道可有多条；偏出航道可能撞礁。答对但曾搁浅=虚假推理。

形式定义

原型 / 盆地 / alarm

$$d_*(h, c) = \sqrt{(h - c)^\top G (h - c)};$$
$$\text{basin}(h) = \arg \min_k d_*(h, e_k); \text{ 阈值化 alarm.}$$

物理直觉

灯塔距离与偏航警报

灯塔=正确原型；雷达距离拉大就鸣笛；被错误漩涡吸住=进盆地。 t^* 是第一次能稳定分辨「这船要完」的时刻。

C.8 相关与因果（总原则）

形式定义

相关（读出）

存在统计关联：探针风险低于基线；Acc, AUC 等。

物理直觉

温度计读数与天气相关

你能从仪表猜外面冷不冷，但拧温度计不会改变天气。

形式定义

因果（干预）

存在 α 区间使 $\Delta(\alpha) > \Delta_{\text{rand}}(\alpha) + \delta$ 且退化受控。

物理直觉

扳道岔真的改变列车去向

只有扳道岔后车往另一边开，才能说这根杆「控制」线路。随机瞎扳作对照。

记忆口诀（RapidAi Research）：左栏写进公式本，右栏写进直觉本；做实验前两者对齐；写结论时相关与因果分家。

感谢阅读

大语言模型中的流形原理与应用

自学工坊 · 理论形象卡 · 物理直觉 · 可复现实验

作者 / 编撰: **RapidAI Research**

主页: <https://rapidai.tech/research/>

建议路径: §0 -> §0E -> §0F -> §0A 双栏 -> Lab0

RapidAI Research · <https://rapidai.tech/research/> · v2.5.0 · 2026-08-13